

Report Modelli Statistici per Dati Economici

Riccardo Forte - Matricola: 2160531

Table of contents

Introduzione	3
Dati	3
Analisi esplorative	4
Grafici serie storiche	4
Correlogrammi	7
Test di Dickey-Fuller Aumentato (ADF)	9
VECM (Vector Error Correction Model)	20
Test di Johansen	20
Vettore di Cointegrazione (VECM)	25
Trasformazione: Tassi di Crescita (Differenze Logaritmiche)	27
Cross-correlazioni (CCF)	28
Pulizia autocorrelazione nelle serie storiche	28
Grafici cross-correlazioni	34
Selezione e Stima Modello VAR	36
Stima del Modello VAR(1)	37
Stima del Modello VAR(2)	43
Diagnostica VAR(2)	48
Analisi di Causalità (Granger)	51
Impulse Response Function (IRF)	57
Forecast Error Variance Decomposition (FEVD)	61
Modello a funzione di trasferimento (TFM)	62
Prewhitening e CCF sui residui	63
Stima del modello	64
ARIMAX	68
Struttura del Modello	69
Previsioni	69
Calcolo previsioni nell'insieme di stima	70
Valori stimati dai modelli nell'insieme di stima	73
Visualizzazione grafica delle previsioni	78

Errori di previsione e metriche	82
Conclusioni Finali	90
Appendice	91
Uso Intelligenza Artificiale	91

Introduzione

In questo elaborato si andrà a considerare tre serie storiche mensili scaricate dal database “FRED”:

- **INDPRO (Industrial Production Index):** L’indice della produzione industriale misura l’output reale dei settori manifatturiero, minerario e dei servizi di pubblica utilità (gas ed elettricità). Rappresenta una misura tempestiva della componente più ciclica dell’economia, fornendo un segnale immediato sulle fasi di espansione o contrazione dell’attività fisica produttiva.
- **PAYEMS (All Employees, Total Nonfarm):** Questa serie rappresenta il numero totale di dipendenti nel settore non agricolo. È la misura di riferimento per la salute del mercato del lavoro statunitense. Essendo una variabile di stock (numero di posti di lavoro esistenti), riflette come le decisioni delle imprese si adattino all’andamento della domanda e della produzione.
- **W875RX1 (Real personal income excluding current transfer receipts):** Questa serie misura il reddito personale reale al netto dei trasferimenti governativi (come sussidi o pensioni). È considerata una delle migliori proxy mensili del PIL, poiché riflette la capacità di spesa generata direttamente dall’attività produttiva e dal mercato del lavoro, depurata dalle componenti transitorie della politica fiscale.

Le serie considerate delineano il nucleo della trasmissione macroeconomica tra produzione, reddito e occupazione. Esse sono legate da relazioni di feedback fondamentali: un incremento della produzione industriale (**INDPRO**) richiede solitamente un aumento dell’input di lavoro (**PAYEMS**), il quale a sua volta genera reddito reale per le famiglie (**W875RX1**), sostenendo la domanda aggregata. In econometria, queste variabili sono spesso analizzate congiuntamente poiché tendono a muoversi in sincronia durante il ciclo economico, sebbene con velocità di aggiustamento differenti. Mentre la produzione industriale reagisce rapidamente agli shock, l’occupazione tende a mostrare una maggiore persistenza (o ritardo), a causa dei costi di assunzione e licenziamento.

Dati

Come prima cosa carico tutte le librerie necessarie per le analisi e le funzioni che verranno utilizzate all’interno del report.

```
library(forecast)
library(urca)
library(vars)
library(dynlm)
source("Funzioni.lib")
```

Carico i dati

```
dati = readxl::read_xlsx("dati_report.xlsx")
Serie = ts(dati, start = c(1980,1), frequency = 12)
colnames(Serie) = c("Prod", "Occ", "Redd")
tail(Serie)
```

		Prod	Occ	Redd
Apr	2025	101.1279	159433	16700.0
May	2025	100.9655	159452	16636.1
Jun	2025	101.4785	159439	16583.5
Jul	2025	101.8738	159511	16639.8
Aug	2025	101.6019	159485	16641.5
Sep	2025	101.6729	159593	16654.3

Analisi esplorative

L'analisi dei grafici delle serie storiche possono essere d'aiuto per l'individuazione di trend e pattern particolari nel tempo.

Grafici serie storiche

```
plot.ts(Serie)
```




Figure 1: Grafici delle serie storiche: Produzione Industriale, occupazione non agricola, Reddito Reale Personale.

Le serie storiche presentano tutte e tre un chiaro trend crescente nel lungo periodo, ma mostrano differenze sostanziali nella loro reattività ai cicli economici:

- **Produzione Industriale (INDPRO):** La serie mostra il comportamento più ciclico e volatile del sistema. Presenta contrazioni marcate in corrispondenza di ogni recessione economica, con cadute particolarmente evidenti durante la crisi finanziaria del 2008 e la pandemia del 2020. È evidente come la produzione industriale sia la variabile che reagisce con maggior reattività ed intensità ai cambiamenti economici.
- **Occupazione Non Agricola (PAYEMS):** La serie dell'occupazione presenta un trend molto più persistente e meno variabile rispetto alla produzione, ma con una caratteristica dinamica di ritardo. Durante le recessioni (2001, 2008), i cali sono profondi ma più gradualmente, mentre il recupero post-crisi tende a essere più lento. Lo shock del 2020 appare unico nella serie per la sua verticalità, riflettendo la natura esogena del lockdown, seguita da una fase di crescita quasi costante.
- **Reddito Personale Reale (W875RX1):** Questa serie mostra la crescita più regolare

e monotona, riflettendo una componente strutturale di lungo periodo molto forte. Pur risentendo delle recessioni, le sue fluttuazioni sono meno ampie rispetto alla produzione industriale. Dopo lo shock pandemico si è registrata una crescita più rapida rispetto alle altre due serie.

Tutte e tre le serie mostrano chiari segnali di non stazionarietà, caratterizzate da trend deterministici o stocastici che richiedono una verifica formale tramite correlogrammi e test di Dickey-Fuller (ADF). Data la natura macroeconomica dei dati e la presenza di trend che appaiono esponenziali nel lungo periodo, l'applicazione della trasformazione logaritmica risulta fondamentale. Questa operazione permetterà di linearizzare le tendenze, stabilizzare la varianza e, in seguito alla differenziazione, interpretare i dati in termini di tassi di crescita mensili, facilitando l'analisi delle interdipendenze dinamiche dei modelli VAR e VECM.

```
Log.Serie = log(Serie)
plot.ts(Serie)
```




Figure 2: Grafici della trasformata logaritmica delle serie storiche: Produzione Industriale, occupazione non agricola, Reddito Reale Personale.

```
# Suddivisione in insieme di stima e verifica
stima = window(Log.Serie, end = c(2021, 6))
test = window(Log.Serie, start = c(2021, 7))
plot.ts(stima)
```




Figure 3: Grafici della trasformata logaritmica delle serie storiche solo all'interno dell'insieme di stima.

Correlogrammi

```
par(mfrow=c(1,2))
acf(stima[,1],main="Produzione Industriale")
pacf(stima[,1],main="Produzione Industriale")
```




Figure 4: Correlogrammi della serie storica: Produzione Industriale.

```
par(mfrow=c(2,2))
acf(stima[,2],main="Occupazione Non Agricola")
pacf(stima[,2],main="Occupazione Non Agricola")
acf(stima[,3],main="Reddito Personale Reale")
pacf(stima[,3],main="Reddito Personale Reale")
```




Figure 5: Correlogrammi delle serie storiche: Occupazione Non Agricola e Reddito Personale Reale.

Tutte e tre le funzioni di autocorrelazione globale (ACF) decrescono molto lentamente indice che non sono stazionarie, mentre le funzioni di autocorrelazione parziale (PACF) hanno un picco molto forte al lag 1.

Test di Dickey-Fuller Aumentato (ADF)

Utilizzando il test della radice unitaria di Dickey-Fuller aumentato (ur.df) si testa l'ipotesi di presenza di una radice unitaria evidenziata nei correlogrammi e grafici delle serie storiche.

La procedura prevede di analizzare una serie alla volta seguendo un approccio sequenziale, prima con trend e costante, poi solo con drift (costante), e infine senza termini deterministici se necessario.

Per i seguenti test si utilizzerà un livello di significatività pari a 0.05 e si selezioneranno i lag ottimali col criterio BIC, ottenendo la seguente equazione:

$$\Delta y_{t-1} = \alpha + \gamma t + \delta y_{t-1} + \sum_{j=1}^p \beta_j \Delta y_{t-j} + \varepsilon_t$$

Produzione Industriale

```
# --- Passo 1: Modello con Trend e Costante ---
test_prod_trend = ur.df(stima[,1], type="trend",
                        selectlags = "BIC",lags = 12)
summary(test_prod_trend)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.133862	-0.003478	0.000510	0.003901	0.058330

Coefficients:

```

              Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.244e-02  1.966e-02   1.141    0.254
z.lag.1      -5.133e-03  4.970e-03  -1.033    0.302
tt           4.232e-06  8.722e-06   0.485    0.628
z.diff.lag   2.140e-01  4.466e-02   4.793  2.2e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```

Residual standard error: 0.00981 on 481 degrees of freedom
Multiple R-squared:  0.05137,    Adjusted R-squared:  0.04546
F-statistic: 8.683 on 3 and 481 DF,  p-value: 1.277e-05

```

Value of test-statistic is: -1.0327 2.8827 1.38

Critical values for test statistics:

```

      1pct  5pct 10pct
tau3 -3.98 -3.42 -3.13
phi2  6.15  4.71  4.05
phi3  8.34  6.30  5.36

```

Per la produzione industriale (in logaritmi) è stato effettuato un test di Dickey-Fuller aumentato includendo all'inizio sia il trend che il drift. Dato che si hanno dati mensili si è deciso di includere anche i ritardi delle differenze prime selezionandoli con una procedura che valuta il criterio di informazione BIC.

Da questo primo test si nota che:

- **tau3:** il valore della statistica (-1.0327) è maggiore del valore critico al 5% (-3.42), quindi non si rifiuta l'ipotesi nulla di presenza di una radice unitaria ($H_0 : \delta = 0$).
- **phi2:** il valore (2.8827) è minore del valore critico (4.71), quindi non si rifiuta l'ipotesi nulla che il drift e il trend temporale siano nulli in presenza di una radice unitaria ($H_0 : \delta = \gamma = \alpha = 0$).
- **phi3:** il valore (1.38) è minore del valore critico (6.30), quindi non si rifiuta l'ipotesi nulla di presenza di una radice unitaria e assenza del trend temporale ($H_0 : \delta = \gamma = 0$)

Dato che il trend non è significativamente diverso da 0 (phi3), lo rimuoviamo e proseguiamo utilizzando il test di Dickey-Fuller aumentato includendo il solo drift per confermare che non sia presente anche il trend:

```

# --- Passo 2: Modello con Drift ---
test_prod_drift = ur.df(stima[,1], type="drift",lags=12,selectlags = "BIC")
summary(test_prod_drift)

```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression drift

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.132224	-0.003404	0.000507	0.003983	0.044219

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.014277	0.007911	1.805	0.0717 .
z.lag.1	-0.002989	0.001807	-1.654	0.0987 .
z.diff.lag1	0.235762	0.045164	5.220	2.66e-07 ***
z.diff.lag2	-0.113123	0.045169	-2.504	0.0126 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.009749 on 481 degrees of freedom

Multiple R-squared: 0.06313, Adjusted R-squared: 0.05728

F-statistic: 10.8 on 3 and 481 DF, p-value: 7.011e-07

Value of test-statistic is: -1.6545 4.9929

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.44	-2.87	-2.57
phi1	6.47	4.61	3.79

Utilizzando il test di Dickey-Fuller aumentato includendo il solo drift (costante), osserviamo che:

- **tau2:** il valore (-1.6545) è maggiore del valore critico (-2.87), quindi non si rifiuta l'ipotesi nulla di presenza di una radice unitaria.

- **phi1:** il valore (4.9929) è maggiore del valore critico (4.61), quindi si rifiuta l'ipotesi nulla di presenza di una radice unitaria e assenza del trend temporale.

Essendo il test phi1 significativo e avendo accettato la presenza di radice unitaria (tau2), possiamo concludere che il drift è significativo. Pertanto, la serie della produzione industriale in logaritmi presenta una radice unitaria con drift (è un Random Walk con Drift).

Occupazione Non Agricola

```
# --- Passo 1: Modello con Trend e Costante ---
test_occ_trend = ur.df(stima[,2],type="trend",selectlags = "BIC",lags = 12)
summary(test_occ_trend)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.145658	-0.000549	0.000581	0.001380	0.022728

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.106e-01	8.005e-02	1.382	0.16756
z.lag.1	-9.492e-03	6.989e-03	-1.358	0.17503
tt	6.284e-06	7.435e-06	0.845	0.39844
z.diff.lag1	4.139e-02	4.525e-02	0.915	0.36079
z.diff.lag2	-1.400e-01	4.528e-02	-3.091	0.00211 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.007098 on 480 degrees of freedom

Multiple R-squared: 0.02913, Adjusted R-squared: 0.02104

F-statistic: 3.6 on 4 and 480 DF, p-value: 0.006629

Value of test-statistic is: -1.3582 4.8452 1.9519

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-3.98	-3.42	-3.13
phi2	6.15	4.71	4.05
phi3	8.34	6.30	5.36

Per l'occupazione non agricola (in logaritmi) è stato effettuato un test di Dickey-Fuller aumentato includendo all'inizio sia il trend che il drift. Dato che si hanno dati mensili si è deciso di includere anche i ritardi delle differenze prime selezionandoli con una procedura che valuta il criterio di informazione BIC.

Da questo primo test si nota che:

- **tau3:** il valore della statistica (-1.3582) è maggiore del valore critico al 5% (-3.42), quindi non si rifiuta l'ipotesi nulla di presenza di una radice unitaria ($H_0 : \delta = 0$).
- **phi2:** il valore (4.8452) è maggiore del valore critico (4.71), quindi si rifiuta l'ipotesi nulla che il drift e il trend temporale siano nulli in presenza di una radice unitaria.
- **phi3:** il valore (1.9519) è minore del valore critico (6.30), quindi non si rifiuta l'ipotesi nulla di presenza di una radice unitaria e assenza del trend temporale.

Dato che il trend non è significativamente diverso da 0 (phi3), lo rimuoviamo e proseguiamo utilizzando il test di Dickey-Fuller aumentato includendo il solo drift per confermare che non sia presente anche il trend:

```
# --- Passo 2: Modello con Drift ---
test_occ_drift = ur.df(stima[,2], type="drift",lags=12,selectlags = "BIC")
summary(test_occ_drift)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression drift

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.145450	-0.000671	0.000599	0.001342	0.023211

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.046495	0.025430	1.828	0.06812 .
z.lag.1	-0.003878	0.002171	-1.786	0.07466 .
z.diff.lag1	0.037687	0.045026	0.837	0.40301
z.diff.lag2	-0.143911	0.045027	-3.196	0.00148 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.007096 on 481 degrees of freedom

Multiple R-squared: 0.02768, Adjusted R-squared: 0.02162

F-statistic: 4.565 on 3 and 481 DF, p-value: 0.003641

Value of test-statistic is: -1.7864 6.9147

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.44	-2.87	-2.57
phi1	6.47	4.61	3.79

Utilizzando il test di Dickey-Fuller aumentato includendo il solo drift (costante), osserviamo che:

- **tau2:** il valore (-1.7864) è maggiore del valore critico (-2.87), quindi non rifiuto l'ipotesi nulla di presenza di una radice unitaria.
- **phi1:** il valore (6.9147) è maggiore del valore critico (4.61), quindi si rifiuta l'ipotesi nulla di presenza di una radice unitaria e assenza del trend temporale.

Essendo il test phi1 significativo e avendo accettato la presenza di radice unitaria (tau2), possiamo concludere che il drift è significativo. Pertanto, la serie dell'occupazione in logaritmi presenta una radice unitaria con drift.

Reddito Personale Reale

```
# --- Passo 1: Modello con Trend e Costante ---
test_redd_trend = ur.df(stima[,3],type="trend",selectlags = "BIC",lags = 12)
summary(test_redd_trend)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression trend

Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
      Min       1Q   Median       3Q      Max
-0.066792 -0.002271  0.000224  0.002623  0.037501

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.133e-01  6.111e-02   1.855   0.0643 .
z.lag.1      -1.286e-02  7.104e-03  -1.810   0.0710 .
tt           2.564e-05  1.531e-05   1.675   0.0946 .
z.diff.lag   -4.345e-02  4.548e-02  -0.955   0.3399
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.00722 on 481 degrees of freedom
Multiple R-squared:  0.01021,    Adjusted R-squared:  0.004039
F-statistic: 1.654 on 3 and 481 DF,  p-value: 0.1761

Value of test-statistic is: -1.8097 16.4318 1.9119

Critical values for test statistics:
      1pct  5pct 10pct
tau3 -3.98 -3.42 -3.13
phi2  6.15  4.71  4.05
phi3  8.34  6.30  5.36
```

Per i Reddito Personale Reale (in logaritmi) è stato effettuato un test di Dickey-Fuller aumentato includendo all'inizio sia il trend che il drift. Dato che si hanno dati mensili si è deciso di includere anche i ritardi delle differenze prime selezionandoli con una procedura che valuta il criterio di informazione BIC.

Da questo primo test si nota che:

- **tau3:** il valore della statistica (-1.8097) è maggiore del valore critico al 5% (-3.42), quindi non si rifiuta l'ipotesi nulla di presenza di una radice unitaria ($H_0 : \delta = 0$).
- **phi2:** il valore (16.4318) è maggiore del valore critico (4.71), quindi si rifiuta l'ipotesi nulla che il drift e il trend temporale siano nulli in presenza di una radice unitaria.
- **phi3:** il valore (1.9119) è minore del valore critico (6.30), quindi non si rifiuta l'ipotesi nulla di presenza di una radice unitaria e assenza del trend temporale.

Dato che il trend non è significativamente diverso da 0 (phi3), lo rimuoviamo e proseguiamo utilizzando il test di Dickey-Fuller aumentato includendo il solo drift.

```
# --- Passo 2: Modello con Drift ---
test_redd_drift = ur.df(stima[,3], type="drift",lags=12,selectlags = "BIC")
summary(test_redd_drift)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression drift

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.066368	-0.002333	0.000303	0.002557	0.037809

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.012347	0.009972	1.238	0.216
z.lag.1	-0.001097	0.001089	-1.007	0.314
z.diff.lag	-0.049247	0.045435	-1.084	0.279

Residual standard error: 0.007234 on 482 degrees of freedom

Multiple R-squared: 0.004439, Adjusted R-squared: 0.0003077

F-statistic: 1.074 on 2 and 482 DF, p-value: 0.3423

Value of test-statistic is: -1.0072 23.1581

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.44	-2.87	-2.57
phi1	6.47	4.61	3.79

Utilizzando il test di Dickey-Fuller aumentato includendo il solo drift (costante), osserviamo che:

- **tau2:** il valore (-1.0072) è maggiore del valore critico (-2.87), quindi non rifiuto l'ipotesi nulla di presenza di una radice unitaria.
- **phi1:** il valore (23.1581) è maggiore del valore critico (4.61), quindi si rifiuta l'ipotesi nulla di presenza di una radice unitaria e assenza del drift.

Essendo il test phi1 significativo e avendo accettato la presenza di radice unitaria (tau2), possiamo concludere che il drift è significativo. Pertanto, la serie del reddito in logaritmi presenta una radice unitaria con drift (è un Random Walk con Drift).

Analisi differenze prime

Per concludere la fase di test e confermare definitivamente che possiamo trattare le serie come $I(1)$ (cioè stazionarie una volta differenziate), si esegue il test ADF sulle differenze prime di tutte e tre le variabili.

```
# --- Verifica sulle Differenze Prime (per confermare I(1)) ---  
# Produzione Industriale (Differenze)  
summary(ur.df(diff(stima[,1]), type="drift", lags=12, selectlags = "BIC"))
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression drift

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.132796	-0.003630	0.000542	0.004249	0.044320

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	0.0012166	0.0004511	2.697	0.00724	**
z.lag.1	-0.8736537	0.0568004	-15.381	< 2e-16	***
z.diff.lag	0.1109697	0.0453046	2.449	0.01466	*

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.009776 on 481 degrees of freedom

Multiple R-squared: 0.4008, Adjusted R-squared: 0.3983

F-statistic: 160.9 on 2 and 481 DF, p-value: < 2.2e-16

Value of test-statistic is: -15.3811 118.2911

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.44	-2.87	-2.57
phi1	6.47	4.61	3.79

```
# Occupazione non agricola (Differenze)
summary(ur.df(diff(stima[,2]), type="drift", lags=12, selectlags = "BIC"))
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression drift

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.146251	-0.000566	0.000445	0.001269	0.023326

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	0.0010690	0.0003292	3.248	0.00124	**

```
z.lag.1      -1.1015050  0.0627409 -17.556 < 2e-16 ***
z.diff.lag   0.1415654  0.0451586   3.135  0.00182 **
---
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.007119 on 481 degrees of freedom
Multiple R-squared: 0.4926, Adjusted R-squared: 0.4905
F-statistic: 233.5 on 2 and 481 DF, p-value: < 2.2e-16

Value of test-statistic is: -17.5564 154.1144

Critical values for test statistics:

```
      1pct  5pct 10pct
tau2 -3.44 -2.87 -2.57
phi1  6.47  4.61  3.79
```

```
# Reddito Reale Personale (Differenze)
summary(ur.df(diff(stima[,3]), type="drift", lags=12, selectlags = "BIC"))
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression drift

Call:

```
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-0.066746 -0.002473  0.000296  0.002702  0.037516
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.0024826  0.0003588   6.918 1.47e-11 ***
z.lag.1      -1.1221570  0.0658244 -17.048 < 2e-16 ***
z.diff.lag    0.0693522  0.0454475   1.526   0.128
---
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.007227 on 481 degrees of freedom
Multiple R-squared: 0.5273, Adjusted R-squared: 0.5253
F-statistic: 268.2 on 2 and 481 DF, p-value: < 2.2e-16

Value of test-statistic is: -17.0477 145.3149

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.44	-2.87	-2.57
phi1	6.47	4.61	3.79

I test sulle differenze prime mostrano un rifiuto di H_0 . Poiché per tutte le variabili non abbiamo rifiutato la presenza di radice unitaria sui livelli, ma abbiamo rifiutato la radice unitaria sulle differenze prime, concludiamo che produzione industriale, occupazione non agricola e reddito personale sono processi integrati di ordine 1, ovvero $I(1)$. Quindi è possibile procedere con l'analisi di cointegrazione.

VECM (Vector Error Correction Model)

Test di Johansen

Prima di stimare il VECM si va a determinare il rango di cointegrazione (massimo due vettori di integrazione visto che si hanno solo tre serie), se esiste almeno un vettore di cointegrazione ha senso andare a stimare un VECM.

```
# 1. Selezione del numero di ritardi (Lag Length)
lag_select = VARselect(stima, lag.max = 12, type = "both")
print(lag_select$selection)
```

AIC(n)	HQ(n)	SC(n)	FPE(n)
11	4	2	11

```
K_opt = lag_select$selection['SC(n)']
```

Si seleziona il valore tramite il criterio d'informazione BIC in quanto il più robusto e risulta la soluzione più parsimoniosa.

Per determinare il numero di relazioni di cointegrazione (r), si adotta la procedura di Johansen con la specifica $ecdet = \text{"const"}$. Tale scelta è supportata dai risultati dei test ADF precedentemente condotti, i quali hanno escluso la presenza di trend deterministici significativi nelle serie in livelli (test ϕ_3 non significativo), confermando invece la presenza di componenti di drift (test ϕ_1 significativo), inoltre le differenze delle serie storiche riscalate non evidenziano trend crescenti o decrescenti evidenti.

```
Stima.scale = scale(stima)
par(mfrow=c(3,1))
plot.ts(Stima.scale[,1]-Stima.scale[,2],main="Differenza tra prod e occ")
plot.ts(Stima.scale[,1]-Stima.scale[,3],ylab="Differenza tra prod e redd")
plot.ts(Stima.scale[,2]-Stima.scale[,3],ylab="Differenza tra occu e redd")
```




Figure 6: Grafici delle differenze tra le serie riscalate

Si assume pertanto che le serie presentino trend lineari stocastici che si annullano nella relazione

di cointegrazione, lasciando un equilibrio di lungo periodo stazionario attorno a una costante.

Test della Traccia

```
# Test di Cointegrazione (Trace Test)
vecm_jo = ca.jo(stima, type = "trace", ecdet = "const",
               K = K_opt, spec = "longrun")
summary(vecm_jo)
```

```
#####
# Johansen-Procedure #
#####
```

Test type: trace statistic , without linear trend and constant in cointegration

Eigenvalues (lambda):

```
[1] 9.846748e-02 1.298689e-02 3.317188e-03 -3.275495e-16
```

Values of teststatistic and critical values of test:

	test	10pct	5pct	1pct
r <= 2	1.65	7.52	9.24	12.97
r <= 1	8.13	17.85	19.96	24.60
r = 0	59.55	32.00	34.91	41.07

Eigenvectors, normalised to first column:

(These are the cointegration relations)

	Prod.l2	Occ.l2	Redd.l2	constant
Prod.l2	1.00000000	1.00000000	1.00000000	1.00000000
Occ.l2	-1.75688339	-3.0237350	-0.7015755	3.391649
Redd.l2	0.02420219	0.6007782	-0.3395014	-2.933375
constant	16.21938299	25.5384514	6.9485524	-17.283615

Weights W:

(This is the loading matrix)

	Prod.l2	Occ.l2	Redd.l2	constant
Prod.d	0.003476541	0.010991781	-0.0068174166	-1.798037e-14
Occ.d	0.002821344	0.011193577	-0.0004656440	-1.194646e-14
Redd.d	0.009852970	0.002772563	-0.0007840871	-1.375660e-14

Verifichiamo sequenzialmente le ipotesi nulle:

- $H_0: r = 0 \rightarrow$ La statistica test è 59.55, nettamente maggiore al valore critico al 5% (42.44), quindi si rifiuta H_0 .
- $H_0: r \leq 1 \rightarrow$ La statistica test è 8.13, nettamente inferiore al valore critico al 5% (19.96), quindi non si rifiuta H_0 .
- $H_0: r \leq 2 \rightarrow$ La statistica test è 1.65, nettamente inferiore al valore critico al 5% (9.24), quindi non si rifiuta H_0 .

Test dell'Autovalore Massimo (Max Eigenvalue)

```
vecm_eigen = ca.jo(stima, type = "eigen", ecdet = "const",  
                  K = K_opt, spec = "longrun")  
summary(vecm_eigen)
```

```
#####  
# Johansen-Procedure #  
#####
```

Test type: maximal eigenvalue statistic (lambda max) , without linear trend and constant in c

Eigenvalues (lambda):

```
[1] 9.846748e-02 1.298689e-02 3.317188e-03 -3.275495e-16
```

Values of teststatistic and critical values of test:

	test	10pct	5pct	1pct
$r \leq 2$		1.65	7.52	9.24 12.97
$r \leq 1$		6.48	13.75	15.67 20.20
$r = 0$		51.41	19.77	22.00 26.81

Eigenvectors, normalised to first column:

(These are the cointegration relations)

	Prod.12	Occ.12	Redd.12	constant
Prod.12	1.00000000	1.00000000	1.00000000	1.000000
Occ.12	-1.75688339	-3.0237350	-0.7015755	3.391649
Redd.12	0.02420219	0.6007782	-0.3395014	-2.933375
constant	16.21938299	25.5384514	6.9485524	-17.283615

Weights W:

(This is the loading matrix)

	Prod.12	Occ.12	Redd.12	constant
Prod.d	0.003476541	0.010991781	-0.0068174166	-1.798037e-14
Occ.d	0.002821344	0.011193577	-0.0004656440	-1.194646e-14
Redd.d	0.009852970	0.002772563	-0.0007840871	-1.375660e-14

```
plotres(vecm_jo)
```




Figure 7: Grafici e correlogrammi dei residui del VAR ausiliario per i test di Johansen.




Figure 8: Grafici e correlogrammi dei residui del VAR ausiliario per i test di Johansen.




Figure 9: Grafici e correlogrammi dei residui del VAR ausiliario per i test di Johansen.

Verifichiamo sequenzialmente le ipotesi nulle:

- $H_0: r = 0 \rightarrow$ La statistica test è 51.41, nettamente superiore al valore critico al 5% (22), quindi si rifiuta H_0 .
- $H_0: r \leq 1 \rightarrow$ La statistica test è 6.48, inferiore al valore critico al 5% (15.67), quindi non si rifiuta H_0 .
- $H_0: r \leq 2 \rightarrow$ La statistica test è 1.65, nettamente inferiore al valore critico al 5% (9.24), quindi non si rifiuta H_0 .

Entrambi i test indicano concordemente che il rango di cointegrazione è $r = 1$. Esiste quindi un vettore di cointegrazione (una relazione di equilibrio di lungo periodo) che lega le variabili considerate. Questo risultato implica che le variabili condividono un trend stocastico comune che le mantengono legate nel lungo termine, nonostante le deviazioni di breve periodo.

Vettore di Cointegrazione (VECM)

Si normalizza per la prima variabile, la produzione industriale.

Relazioni di Lungo Periodo (Matrice β)

```
# Si stima il VECM ristretto con rango r = 1
vecm_rls = cajorls(vecm_jo, r = 1)
# Si mostra i coefficienti delle relazioni di lungo periodo (Beta)
print(round(vecm_rls$beta, 2))
```

	ect1
Prod.12	1.00
Occ.12	-1.76
Redd.12	0.02
constant	16.22

L'output mostra la relazione di equilibrio :

- Relazione (Normalizzata sulla produzione industriale):

$$\ln(\text{Prod}) = -16.22 - 0.02 \ln(\text{Redd}) + 1.76 \ln(\text{Occ})$$

La relazione di lungo periodo mostra che la produzione industriale è legata positivamente all'occupazione (elasticità di 1.76): un aumento dell'1% dell'occupazione è associato a un aumento dell'1.76% della produzione nel lungo periodo. Il reddito, curiosamente, ha un segno negativo quasi nullo (-0.02), suggerendo che, una volta controllata l'occupazione, il reddito non aggiunge informazione strutturale alla capacità produttiva.

Coefficienti di Aggiustamento (Matrice α)

```
# Coefficienti di aggiustamento (Alpha / Loading Matrix)
print(vecm_rls$rlm$coefficients[grep("ect",
                                     rownames(vecm_rls$rlm$coefficients)), ])
```

	Prod.d	Occ.d	Redd.d
	0.003476541	0.002821344	0.009852970

I coefficienti di aggiustamento (α) risultano estremamente bassi per tutte le variabili. In particolare:

- **Produzione e Occupazione:** Con valori vicini allo zero e segni positivi, queste variabili non sembrano correggere gli squilibri di breve periodo. Questo suggerisce che siano variabili “guida” (esogene nel lungo periodo) che non si adattano agli errori del sistema.
- **Reddito:** Sebbene sia il valore più alto (0.009), rimane comunque troppo contenuto per indicare un riassorbimento rapido.

I coefficienti α non presentano il segno atteso per il riequilibrio, suggerendo che le variabili si muovano insieme spinte da trend comuni piuttosto che da una reazione dinamica agli scostamenti dall'equilibrio. Questo fenomeno è spesso associato a variabili debolmente esogene o a sistemi dove il riequilibrio richiede tempi molto lunghi, superiori alla frequenza mensile dei dati.

In sintesi, sebbene il test di Johansen identifichi una relazione di cointegrazione ($r = 1$), l'assenza di coefficienti di aggiustamento α significativi (o con il segno atteso) indica che il meccanismo di correzione dell'errore è quasi inesistente o estremamente lento. Alla luce di questa evidenza, si è ritenuto non necessario procedere con la metodologia alternativa di Engle-Granger. Sebbene tale procedura permetta di stimare il vettore di cointegrazione tramite OLS minimizzando la varianza residua, la debolezza strutturale dei parametri di aggiustamento emersa nel test di Johansen suggerisce che anche un modello ECM basato sui residui OLS mostrerebbe una scarsa capacità di riequilibrio. Questo conferma che, pur non divergendo nel lunghissimo periodo, la dinamica mensile delle serie è dominata da shock stocastici di breve termine. Pertanto, per catturare correttamente le interdipendenze cicliche e produrre previsioni accurate, risulta metodologicamente preferibile procedere con un modello VAR in differenze prime.

Trasformazione: Tassi di Crescita (Differenze Logaritmiche)

Per affrontare la non stazionarietà (trend) osservata nei dati in livelli, si applica una trasformazione in differenze logaritmiche. Questo permette di analizzare i tassi di crescita mensili approssimati, che dovrebbero essere stazionari.

```
# Trasformazione dell'intero insieme dei dati
dati_trasf = diff(Log.Serie)*100

# Calcola le differenze logaritmiche (tassi di crescita)
df = diff(stima) * 100
# --- Grafico delle serie ---
plot.ts(df)
```




Figure 10: Grafici dei tassi di crescita approssimati: Produzione Industriale, Occupazione Non Agricola e Reddito Personale Reale

Cross-correlazioni (CCF)

Pulizia autocorrelazione nelle serie storiche

Prima di rappresentare le funzioni di cross-correlazione è opportuno pulire le serie storiche dall'autocorrelazione, se presente, applicando un modello ARMA(p,q). In questo caso esaminando i vari correlogrammi per ottenere serie prive di correlazione seriale ha senso partire dalle serie differenziate e valutare i correlogrammi per riconoscere pattern autoregressivi e/o a media mobile.

Produzione Industriale

```
plot.ts(df[,1],ylab="Produzione Industriale")
```




Figure 11: Grafico della serie storica differenziata: Produzione Industriale

```
par(mfrow=c(1,2))
acf(df[,1],main="Produzione Industriale",na.action=na.pass)
pacf(df[,1],main="Produzione Industriale",na.action=na.pass)
```




Figure 12: Correlogrammi della serie storica differenziata: Produzione Industriale

```
Box.test(df[,1],24,type="Ljung")
```

Box-Ljung test

```
data: df[, 1]
X-squared = 54.219, df = 24, p-value = 0.0003986
```

Dall'analisi dei correlogrammi e dal test di Ljung-Box è evidente che non basta la differenziazione per sbiancare la serie della produzione industriale. Quindi è necessario utilizzare un opportuno modello ARMA(p,q)

Dalla funzione di autocorrelazione globale della serie dei tassi ha senso proporre un MA(1) o un AR(1).

```
# Stima del modello
fit.p.prod = arima(na.omit(df[,1]),
                  order = c(0,0,1))
fit.p.prod1 = arima(na.omit(df[,1]),
                  order = c(1,0,0))

# Confronto BIC
BIC(fit.p.prod)
```

```
[1] 1407.722
```

```
BIC(fit.p.prod1)
```

```
[1] 1412.708
```

```
#Correlogrammi
par(mfrow=c(1,2))
acf(fit.p.prod$residuals,main="Residui MA(1) - Produzione Industriale")
pacf(fit.p.prod$residuals,main="Residui MA(1) - Produzione Industriale")
```




Figure 13: Correlogrammi dei residui di un MA(1) applicato alla serie differenziata: Produzione Industriale

```
# Controllo stazionarietà ed invertibilità  
check_stationarity_invertibility(fit.p.prod)
```

```
$stationary  
[1] TRUE
```

```
$invertible  
[1] TRUE
```

```
# Test di significatività dei coefficienti stimati  
significativita_arima(fit.p.prod)
```

	Coefficiente	Errore.Standard	Valore.t	P.value
ma1	0.2735598	0.04418621	6.191069	5.975762e-10
intercept	0.1308632	0.05588578	2.341619	1.920032e-02

```
# Test Ljung-Box per correlazione seriale residui  
Box.test(fit.p.prod$residuals,24,type="Ljung",fitdf=1)
```

Box-Ljung test

```
data: fit.p.prod$residuals  
X-squared = 25.726, df = 23, p-value = 0.314
```

```
CCF_prod = fit.p.prod$residuals
```

Il parametro MA risulta significativo ed essendo minore di 1 si ha che il modello è anche invertibile (essendo un MA è sempre stazionario).

Il test di Ljung-Box conferma l'assenza di correlazione seriale nei residui del modello, quindi il modello riesce a catturare la dinamica lineare rimasta all'interno della serie storica differenziata.

Occupazione Non Agricola

```
plot.ts(df[,2],ylab="Occupazione Non Agricola")
```




Figure 14: Grafico della serie storica differenziata: Occupazione Non Agricola

```
par(mfrow=c(1,2))
acf(df[,2],main="Occupazione Non Agricola",na.action=na.pass)
pacf(df[,2],main="Occupazione Non Agricola",na.action=na.pass)
```




Figure 15: Correlogrammi della serie storica differenziata: Occupazione Non Agricola

```
Box.test(df[,2],24,type="Ljung")
```

Box-Ljung test

```
data: df[, 2]
X-squared = 12.861, df = 24, p-value = 0.9684
```

Il test di Ljung-Box non mette in luce evidenza di correlazione seriale all'interno della serie differenziata in quanto non si rifiuta l'ipotesi nulla di incorrelazione seriale

```
CCF_occ = df[,2]
```

Reddito Personale Reale

```
plot.ts(df[,3],ylab="Reddito Personale Reale")
```




Figure 16: Grafico della serie storica differenziata: Reddito Personale Reale

```
par(mfrow=c(1,2))  
acf(df[,3],main="Reddito Personale Reale",na.action=na.pass)  
pacf(df[,3],main="Reddito Personale Reale",na.action=na.pass)
```




Figure 17: Correlogrammi della serie storica differenziata: Reddito Personale Reale

```
Box.test(df[,3],24,type="Ljung")
```

Box-Ljung test

```
data: df[, 3]  
X-squared = 20.238, df = 24, p-value = 0.6832
```

```
CCF_redd =df[,3]
```

La serie differenziata non presenta nessun tipo di correlazione come si può notare dai correlogrammi e il test di Ljung-Box lo conferma. Quindi per questa serie non è necessario filtrarla attraverso un modello ARMA(q,p).

Grafici cross-correlazioni

```
ccf(CCF_prod,CCF_occ,  
    main = "CCF (Produzione Industriale, Occupazione Non Agricola)",  
    na.action = na.pass)
```




Figure 18: Cross-correlazione tra le serie storiche: Produzione Industriale e Occupazione Non Agricola

Dalla funzione di cross-correlazione tra produzione industriale e occupazione emerge una correlazione simultanea statisticamente significativa. Si osserva anche una correlazione significativa

al primo ritardo negativo, indicando che variazioni della produzione industriale precedono quelle dell'occupazione non agricola.

```
ccf(CCF_prod,CCF_redd,  
    main = "CCF (Produzione Industriale, Reddito Personale Reale)",  
    na.action = na.pass)
```




Figure 19: Correlogrammi delle serie storiche: Produzione Industriale e Reddito Personale Reale

La funzione di cross-correlazione tra consumi produzione industriale e reddito personale reale mostra una correlazione simultanea significativa. Emergono due correlazioni leggermente significative a ritardi negativi e una ad un ritardo positivo.

```
ccf(CCF_occ,CCF_redd,  
    main = "CCF (Occupazione Non Agricola, Reddito Personale Reale)",  
    na.action = na.pass)
```




Figure 20: Correlogrammi delle serie storiche: Occupazione Non Agricola e Reddito Personale Reale

Per quanto riguarda la funzione di cross-correlazione tra occupazione e reddito personale, emerge una correlazione simultanea forte e statisticamente significativa e una relazione unidirezionale dove il reddito personale guida l'occupazione in quanto è presente una correlazione significativa al primo ritardo.

Possibile analisi economica delle cross-correlazioni

L'analisi mostra che l'economia si muove come una catena ben sincronizzata, dove la produzione industriale è la forza trainante. Quando la produzione aumenta, l'occupazione non cresce immediatamente, ma con un leggero ritardo. Questo accade perché le aziende preferiscono essere sicure della ripresa prima di assumere nuovo personale. Una volta che l'occupazione inizia a salire, questa trascina con sé il reddito delle famiglie. Infine, si nota un effetto di "ritorno" dove il reddito più alto sostiene i consumi, che a loro volta spingono le imprese a produrre ancora di più. In sintesi, i dati confermano un percorso lineare mostrando che la crescita parte dalle fabbriche, si sposta sui posti di lavoro e arriva infine nelle tasche dei cittadini.

Selezione e Stima Modello VAR

Per selezionare il numero di ritardi (p) del modello VAR, utilizziamo gli indici di informazione su un massimo di 12 lag.

```
ICsel = VARselect(df, lag.max = 12, type = "const")
ICsel$selection
```

AIC(n)	HQ(n)	SC(n)	FPE(n)
10	3	1	10

L'output della funzione VARselect mostra diversi valori di ritardi tra tutti i criteri di informazione. Si preferisce il modello più parsimonioso ed efficiente suggerito dai criteri, procedendo con la stima di un VAR(1).

Stima del Modello VAR(1)

In base ai risultati dei criteri di informazione si procede con la stima del modello VAR(1).

```
modL1 = vars::VAR(df, p = 1, type = "const")
summary(modL1)
```

VAR Estimation Results:

=====

Endogenous variables: Prod, Occ, Redd

Deterministic variables: const

Sample size: 496

Log Likelihood: -1445.827

Roots of the characteristic polynomial:

0.2176 0.1736 0.1736

Call:

vars::VAR(y = df, p = 1, type = "const")

Estimation results for equation Prod:

=====

Prod = Prod.l1 + Occ.l1 + Redd.l1 + const

	Estimate	Std. Error	t value	Pr(> t)	
Prod.l1	0.34326	0.06762	5.077	5.46e-07	***
Occ.l1	-0.32887	0.09887	-3.326	0.000946	***
Redd.l1	0.20525	0.07157	2.868	0.004311	**
const	0.07292	0.04567	1.597	0.110965	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9735 on 492 degrees of freedom

Multiple R-Squared: 0.08445, Adjusted R-squared: 0.07887
 F-statistic: 15.13 on 3 and 492 DF, p-value: 1.972e-09

Estimation results for equation Occ:

=====

Occ = Prod.l1 + Occ.l1 + Redd.l1 + const

	Estimate	Std. Error	t value	Pr(> t)
Prod.l1	0.27261	0.04693	5.809	1.13e-08 ***
Occ.l1	-0.35391	0.06861	-5.158	3.62e-07 ***
Redd.l1	0.18153	0.04967	3.655	0.000285 ***
const	0.05386	0.03169	1.699	0.089880 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6756 on 492 degrees of freedom
 Multiple R-Squared: 0.1015, Adjusted R-squared: 0.09602
 F-statistic: 18.53 on 3 and 492 DF, p-value: 2.114e-11

Estimation results for equation Redd:

=====

Redd = Prod.l1 + Occ.l1 + Redd.l1 + const

	Estimate	Std. Error	t value	Pr(> t)
Prod.l1	0.20811	0.04915	4.234	2.73e-05 ***
Occ.l1	-0.20101	0.07186	-2.797	0.00536 **
Redd.l1	-0.08123	0.05202	-1.561	0.11906
const	0.22756	0.03319	6.856	2.13e-11 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.7076 on 492 degrees of freedom
 Multiple R-Squared: 0.03704, Adjusted R-squared: 0.03116
 F-statistic: 6.308 on 3 and 492 DF, p-value: 0.0003328

Covariance matrix of residuals:

	Prod	Occ	Redd
Prod			
Occ			
Redd			

```
Prod 0.9478 0.4890 0.3240
Occ  0.4890 0.4564 0.2431
Redd 0.3240 0.2431 0.5007
```

Correlation matrix of residuals:

```
      Prod    Occ    Redd
Prod 1.0000 0.7434 0.4703
Occ  0.7434 1.0000 0.5086
Redd 0.4703 0.5086 1.0000
```

L'output del summary relativo al modello VAR(1) con le variabili Prod (Produzione Industriale), Occ (Occupazione) e Redd (Reddito Personale Reale) fornisce le seguenti indicazioni macroeconomiche:

- **Stabilità del Sistema:** Le radici del polinomio caratteristico (0.2176, 0.1736, 0.1736) sono tutte ampiamente inferiori a 1. Questo conferma che il sistema è stazionario e il modello è stabile: gli shock che colpiscono il sistema vengono riassorbiti molto rapidamente, senza mostrare una persistenza esplosiva nel lungo periodo.
- **Analisi delle Equazioni:**
 - **Eq. Prod (Produzione):** A differenza della stima precedente, la produzione attuale mostra ora una significativa inerzia interna (coeff. 0.343, p -value $5.46e - 07$). Restano invece confermati gli effetti delle altre serie: l'occupazione passata mantiene un impatto negativo (-0.329), riflettendo possibili aggiustamenti ciclici, mentre il reddito passato continua a influenzare positivamente la produzione (0.205), suggerendo che la domanda passata stimola l'attività industriale corrente.
 - **Eq. Occ (Occupazione):** Si conferma l'equazione con la maggiore significatività statistica. La produzione passata guida con forza l'occupazione (coeff. 0.273, p -value $1.13e - 08$), ribadendo il ruolo della produzione come traino per il mercato del lavoro. Anche il reddito passato contribuisce positivamente (0.182). Il coefficiente negativo del proprio lag (-0.354) suggerisce una dinamica di "ritorno verso la media" o aggiustamento nei livelli occupazionali.
 - **Eq. Redd (Reddito):** Il reddito è spiegato principalmente dalla produzione industriale passata (coeff. 0.208, p -value $2.73e - 05$) e dall'occupazione (-0.201). Come osservato in precedenza, il reddito non è influenzato dal proprio passato (p -value 0.119), confermando che la ricchezza delle famiglie dipenda strettamente dai flussi reali correnti e passati (produzione e lavoro) piuttosto che da una propria persistenza stocastica.
- **Qualità del Fit (R-squared):** L'occupazione è la variabile meglio modellata ($R^2 \approx 10.1\%$), seguita dalla produzione ($R^2 \approx 8.4\%$) e dal reddito ($R^2 \approx 3.7\%$). Nonostante

i valori possano apparire contenuti, i test F globali sono tutti altamente significativi, confermando la validità statistica della struttura VAR.

- **Residui e Correlazioni Contemporanee:** La matrice di correlazione dei residui evidenzia legami istantanei molto profondi, fondamentali per l'interpretazione macroeconomica:
 - **Correlazione (Prod, Occ) = 0.7434:** Conferma una sincronia quasi totale tra decisioni produttive e variazioni dell'occupazione nello stesso periodo.
 - **Correlazione (Occ, Redd) = 0.5086:** Il legame immediato tra mercato del lavoro e disponibilità economica è solido.
 - **Correlazione (Redd, Prod) = 0.4703:** Esiste un legame contemporaneo moderato tra reddito e produzione. Le elevate correlazioni contemporanee indicano che gli shock macroeconomici colpiscono queste variabili quasi simultaneamente.

Data questa forte interconnessione, per l'analisi delle Impulse Response Functions (IRF) sarà indispensabile utilizzare una decomposizione di Cholesky. Questo permetterà di identificare correttamente la direzione degli impatti, isolando gli shock “puri” di una variabile dagli effetti riflessi dovuti alla correlazione istantanea con le altre.

Residui VAR(1)

```
res_modL1 = resid(modL1)
plot.ts(res_modL1)
```




Figure 21: Grafici dei residui del modello VAR(1)

I grafici dei residui mostrano che sono centrati in zero e che sembra esserci eteroschedasticità, soprattutto per quanto riguarda i residui relativi al reddito.

```
par(mfrow = c(3, 2))
for(i in 1:NCOL(res_modL1)){
  acf(res_modL1[,i], main = colnames(res_modL1)[i])
  pacf(res_modL1[,i], main = colnames(res_modL1)[i])
}
```




Figure 22: Correlogrammi dei residui del modello VAR(1)

I correlogrammi suggeriscono che potrebbe esserci dell'autocorrelazione seriale che non è stata catturata.

Date le diagnosi esplorative dei residui del modello VAR(1) si passa ai test formali.

Diagnostica VAR(1)

Test Univariati sui Residui

Test di Ljung-Box

```
pval = matrix(NA, 2, NCOL(res_modL1))
colnames(pval) = colnames(res_modL1)
rownames(pval) = c("r", "r^2")
for(i in 1:NCOL(res_modL1)){
  # Test per autocorrelazione seriale
  pval[1,i] = Box.test(res_modL1[,i], lag=12, type="Ljung")$p.val
}
```

```
# Test per effetti ARCH (eteroschedasticità)
pval[2,i] = Box.test(res_modL1[,i]^2, lag=12, type="Ljung")$p.val
}
round(pval, 4)
```

	Prod	Occ	Redd
r	0.016	0.0122	0.0521
r^2	0.000	0.9997	0.0001

Questo output fornisce i risultati del test formale per l'autocorrelazione e eteroschedasticità:

- **Autocorrelazione:** La prima riga testa l'ipotesi nulla di assenza di autocorrelazione seriale. Per i residui della serie storica della produzione industriale e dell'occupazione si rifiuta l'ipotesi nulla invece per quella del reddito si accetta con significatività dello 5%
- **Eteroschedasticità:** La seconda riga esegue lo stesso test sui residui al quadrato per verificare la presenza di effetti ARCH (eteroschedasticità). Qui i p -value sono molto bassi e statisticamente significativi per i residui della produzione e reddito, quindi si rifiuta l'ipotesi nulla di omoschedasticità. Invece per quelli dell'occupazione non si rifiuta l'ipotesi nulla di omoschedasticità.

Il modello VAR(1) non è ben specificato per la media (cattura tutta l'autocorrelazione), inoltre i suoi residui presentano eteroschedasticità (la varianza non è costante nel tempo). Quindi è opportuno aumentare l'ordine del modello.

Stima del Modello VAR(2)

In base ai risultati dell'analisi dei residui del modello con un solo lag si passa alla stima di un modello VAR(2).

```
modL2 = vars::VAR(df, p = 2, type = "const")
summary(modL2)
```

```
VAR Estimation Results:
=====
Endogenous variables: Prod, Occ, Redd
Deterministic variables: const
Sample size: 495
Log Likelihood: -1421.934
Roots of the characteristic polynomial:
```

0.3818 0.3727 0.3727 0.3396 0.3396 0.2921

Call:

vars::VAR(y = df, p = 2, type = "const")

Estimation results for equation Prod:

=====

Prod = Prod.l1 + Occ.l1 + Redd.l1 + Prod.l2 + Occ.l2 + Redd.l2 + const

	Estimate	Std. Error	t value	Pr(> t)	
Prod.l1	0.37497	0.06637	5.649	2.74e-08	***
Occ.l1	-0.40287	0.09804	-4.109	4.66e-05	***
Redd.l1	0.19398	0.07092	2.735	0.00646	**
Prod.l2	0.15570	0.06815	2.284	0.02277	*
Occ.l2	-0.51909	0.09872	-5.258	2.18e-07	***
Redd.l2	0.09912	0.07163	1.384	0.16706	
const	0.08631	0.04668	1.849	0.06510	.

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.946 on 488 degrees of freedom

Multiple R-Squared: 0.142, Adjusted R-squared: 0.1314

F-statistic: 13.46 on 6 and 488 DF, p-value: 3.805e-14

Estimation results for equation Occ:

=====

Occ = Prod.l1 + Occ.l1 + Redd.l1 + Prod.l2 + Occ.l2 + Redd.l2 + const

	Estimate	Std. Error	t value	Pr(> t)	
Prod.l1	0.29269	0.04679	6.256	8.64e-10	***
Occ.l1	-0.38401	0.06911	-5.556	4.53e-08	***
Redd.l1	0.17530	0.04999	3.506	0.000496	***
Prod.l2	0.04371	0.04804	0.910	0.363318	
Occ.l2	-0.23319	0.06959	-3.351	0.000867	***
Redd.l2	0.03809	0.05049	0.754	0.450944	
const	0.06316	0.03291	1.919	0.055520	.

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6669 on 488 degrees of freedom

Multiple R-Squared: 0.1317, Adjusted R-squared: 0.1211
 F-statistic: 12.34 on 6 and 488 DF, p-value: 5.939e-13

Estimation results for equation Redd:

=====

Redd = Prod.l1 + Occ.l1 + Redd.l1 + Prod.l2 + Occ.l2 + Redd.l2 + const

	Estimate	Std. Error	t value	Pr(> t)	
Prod.l1	0.21735	0.04928	4.411	1.27e-05	***
Occ.l1	-0.21147	0.07279	-2.905	0.00384	**
Redd.l1	-0.10749	0.05266	-2.041	0.04176	*
Prod.l2	0.12176	0.05060	2.406	0.01648	*
Occ.l2	-0.17081	0.07329	-2.331	0.02018	*
Redd.l2	-0.08131	0.05318	-1.529	0.12695	
const	0.25219	0.03466	7.276	1.38e-12	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.7024 on 488 degrees of freedom
 Multiple R-Squared: 0.05768, Adjusted R-squared: 0.04609
 F-statistic: 4.978 on 6 and 488 DF, p-value: 5.798e-05

Covariance matrix of residuals:

	Prod	Occ	Redd
Prod	0.8950	0.4633	0.3094
Occ	0.4633	0.4447	0.2375
Redd	0.3094	0.2375	0.4933

Correlation matrix of residuals:

	Prod	Occ	Redd
Prod	1.0000	0.7343	0.4656
Occ	0.7343	1.0000	0.5071
Redd	0.4656	0.5071	1.0000

L'output del summary relativo al modello VAR(2) con le variabili Prod (Produzione Industriale), Occ (Occupazione) e Redd (Reddito Personale Reale) fornisce le seguenti indicazioni:

- **Stabilità del Sistema:** Le radici del polinomio caratteristico (0.3818, 0.3727, 0.3727, 0.3396, 0.3396, 0.2921) sono tutte ampiamente inferiori a 1 in modulo. Questo conferma

che il sistema è stazionario e il modello è stabile: gli shock temporanei che colpiscono le variabili non persistono indefinitamente, ma tendono a rientrare nel lungo periodo, garantendo la validità delle inferenze dinamiche.

- **Analisi delle Equazioni:**

- **Eq. Prod (Produzione):** La produzione mostra una forte persistenza sia al primo (0.375) che al secondo lag (0.156). Risultano estremamente significativi gli impatti negativi dell'occupazione passata (-0.403 al lag 1 e -0.519 al lag 2), suggerendo che eccessi occupazionali nei periodi precedenti portino a correzioni della produzione. Il reddito al primo lag influenza positivamente l'output (0.194), confermando il ruolo della domanda passata come stimolo industriale.
- **Eq. Occ (Occupazione):** La produzione industriale al primo lag agisce come driver fondamentale per le nuove assunzioni (0.293, p -value < 0.001). Anche il reddito passato contribuisce positivamente (0.175). È interessante notare che mentre il primo lag dell'occupazione è negativo e significativo (-0.384), l'effetto si protrae significativamente anche al secondo lag (-0.233), indicando un processo di aggiustamento del mercato del lavoro più lungo e articolato rispetto al modello VAR(1).
- **Eq. Redd (Reddito):** Il reddito è spiegato positivamente dalla produzione industriale sia al lag 1 (0.217) che al lag 2 (0.122), evidenziando come la crescita industriale generi flussi di ricchezza con una certa persistenza temporale. L'occupazione passata mostra un effetto negativo e significativo su entrambi i ritardi. La costante risulta molto elevata e significativa (0.252), indicando una componente di crescita autonoma del reddito non catturata dalle variabili reali del sistema.

- **Qualità del Fit (R-squared):** L'inclusione del secondo lag migliora la capacità esplicativa globale. Il modello spiega il 14.2% della varianza della Produzione e l' 13.2% dell'Occupazione. Anche per il Reddito si osserva un miglioramento ($R^2 \approx 5.8\%$). I test F globali sono tutti estremamente significativi (p -value nell'ordine di 10^{-13} per Prod e Occ), validando l'estensione dell'ordine del ritardo a $p = 2$.

- **Correlazioni Contemporanee:** La matrice di correlazione dei residui conferma la presenza di forti legami istantanei, coerentemente con i modelli precedenti:

- **Correlazione (Prod, Occ) = 0.7343:** Persiste una sincronia elevata tra shock produttivi e variazioni occupazionali.
- **Correlazione (Occ, Redd) = 0.5071:** Il legame simultaneo tra lavoro e reddito rimane solido.
- **Correlazione (Redd, Prod) = 0.4656:** Conferma l'interdipendenza immediata tra produzione e reddito.

Nonostante la struttura dinamica sia meglio catturata da due ritardi, rimane una forte componente di shock comuni non anticipati. Per isolare correttamente gli effetti dinamici nelle Impulse Response Functions (IRF), l'adozione di uno schema di identificazione (come la decomposizione di Cholesky) resta il passaggio metodologico fondamentale.

Residui VAR(2)

```
res_modL2 = resid(modL2)
plot.ts(res_modL2)
```




Figure 23: Grafici dei residui del modello VAR(2)

I grafici dei residui mostrano che sono centrati in zero e che sembra esserci eteroschedasticità, soprattutto per quanto riguarda i residui relativi al reddito.

```
par(mfrow = c(3, 2))
for(i in 1:NCOL(res_modL1)){
  acf(res_modL2[,i], main = colnames(res_modL2)[i])
}
```

```
pacf(res_modL2[,i], main = colnames(res_modL2)[i])
}
```




Figure 24: Correlogrammi dei residui del modello VAR(2)

In questo caso i correlogrammi non mettono in luce grosse evidenze che sia presente correlazione seriale residua.

Diagnostica VAR(2)

Test Univariati sui Residui

Test di Ljung-Box

```
pval = matrix(NA, 2, NCOL(res_modL1))
colnames(pval) = colnames(res_modL1)
rownames(pval) = c("r", "r^2")
```

```

for(i in 1:NCOL(res_modL1)){
# Test per autocorrelazione seriale
pval[1,i] = Box.test(res_modL2[,i], lag=12, type="Ljung")$p.val
# Test per effetti ARCH (eteroschedasticità)
pval[2,i] = Box.test(res_modL2[,i]^2, lag=12, type="Ljung")$p.val
}
round(pval, 4)

```

```

      Prod    Occ    Redd
r    0.1290 0.7687 0.1512
r^2  0.0444 1.0000 0.0005

```

Questo output fornisce i risultati del test formale per l'autocorrelazione e eteroschedasticità:

- **Autocorrelazione:** La prima riga testa l'ipotesi nulla di assenza di autocorrelazione seriale. I p -value sono tutti molto alti (0.1290, 0.7687, 0.1512), ben al di sopra della soglia dello 0.05. Accettiamo l'ipotesi nulla e confermiamo formalmente ciò che avevamo visto visivamente: i residui del nostro VAR(1) non sono autocorrelati e si comportano come “rumore bianco”.
- **Eteroschedasticità:** rispetto al modello VAR(1) ci sono dei miglioramenti per quanto riguarda i residui del reddito e soprattutto della produzione ma risultano ancora significativi indice che sia ancora presente eteroschedasticità.

Il nostro modello VAR(2) è ben specificato per la media (cattura tutta l'autocorrelazione), ma i suoi residui presentano eteroschedasticità (la varianza non è costante nel tempo). Sebbene questo non invalidi le stime dei coefficienti, rende gli standard error e i p -value visti nel `summary(modL1)` tecnicamente inaffidabili.

Test Multivariati sui Residui

Si continua l'analisi del VAR(2) con i test multivariati standard per la stabilità, la normalità e l'autocorrelazione seriale.

```

# Test di Stabilità (Radici)
roots(modL2)

```

```

[1] 0.3817569 0.3727170 0.3727170 0.3396221 0.3396221 0.2921185

```

```

# Test di Normalità Multivariata (Jarque-Bera)
normality.test(modL2)

```

\$JB

JB-Test (multivariate)

data: Residuals of VAR object modL2
Chi-squared = 364031, df = 6, p-value < 2.2e-16

\$Skewness

Skewness only (multivariate)

data: Residuals of VAR object modL2
Chi-squared = 6048.2, df = 3, p-value < 2.2e-16

\$Kurtosis

Kurtosis only (multivariate)

data: Residuals of VAR object modL2
Chi-squared = 357983, df = 3, p-value < 2.2e-16

- **Stabilità:** Il test sulle roots (radici) del polinomio caratteristico mostra valori tutti ampiamente inferiori a 1. Questo è un risultato eccellente e conferma che il nostro sistema VAR(2) è stabile.
- **Normalità:** Il test di Jarque-Bera multivariato rifiuta nettamente l'ipotesi nulla di normalità dei residui ($p\text{-value} < 2.2e - 16$). L'output mostra che questo rifiuto è dovuto sia alla presenza di asimmetria (Skewness) sia, e soprattutto, a un eccesso di curtosi (Kurtosis). Questo risultato è molto comune nei dati macroeconomici ed è coerente con quanto già visto nel test sui residui al quadrato (r^2), che indicava la presenza di eteroschedasticità.

```
# Test per Autocorrelazione Seriale (Multivariato)
# Test Ljung-Box multivariato (Portmanteau)
serial.test(modL2, lags.pt=16, type = "PT.asymptotic")
```

Portmanteau Test (asymptotic)

data: Residuals of VAR object modL2
Chi-squared = 213.64, df = 126, p-value = 1.787e-06

```
# Test Breusch-Godfrey (LM Test)
serial.test(modL1, lags.bg = 16, type = "BG")
```

Breusch-Godfrey LM test

```
data: Residuals of VAR object modL1
Chi-squared = 268.67, df = 144, p-value = 1.412e-09
```

I due principali test per l'autocorrelazione seriale multivariata danno risultati concordi però evidenziano correlazione seriale multivariata.

Questo risultato suggerisce fortemente che, nonostante le apparenze, c'è ancora un problema di autocorrelazione seriale nel nostro modello che i test più semplici non hanno rilevato.

ARCH effects (Eteroschedasticità condizionale)

```
vars::arch.test(modL2, lags.multi = 12)
```

ARCH (multivariate)

```
data: Residuals of VAR object modL2
Chi-squared = 1390.1, df = 432, p-value < 2.2e-16
```

Il test ARCH multivariato analizza l'ipotesi nulla di "omoschedasticità", ovvero che i residui abbiano una varianza costante nel tempo. L'output mostra un p -value estremamente piccolo (p -value = $2.2e-16$), che è quindi fortemente significativo. Questo ci porta a rifiutare nettamente l'ipotesi nulla.

Analisi di Causalità (Granger)

Test di sistema

Eseguiamo ora i test di Causalità di Granger per verificare se i ritardi passati di una variabile sono utili a prevedere i valori futuri delle altre variabili. Questo test verifica la significatività congiunta dei coefficienti di una variabile in tutte le equazioni tranne la propria.

H_0 : I ritardi della variabile "cause" NON migliorano la previsione delle altre variabili

```
# Test di sistema (una variabile vs. tutte le altre)
causality(modL2, cause="Prod")
```

\$Granger

Granger causality H0: Prod do not Granger-cause Occ Redd

data: VAR object modL2

F-Test = 11.978, df1 = 4, df2 = 1464, p-value = 1.4e-09

\$Instant

H0: No instantaneous causality between: Prod and Occ Redd

data: VAR object modL2

Chi-squared = 175.84, df = 2, p-value < 2.2e-16

```
causality(modL2, cause="Occ")
```

\$Granger

Granger causality H0: Occ do not Granger-cause Prod Redd

data: VAR object modL2

F-Test = 9.9506, df1 = 4, df2 = 1464, p-value = 6.046e-08

\$Instant

H0: No instantaneous causality between: Occ and Prod Redd

data: VAR object modL2

Chi-squared = 180.54, df = 2, p-value < 2.2e-16

```
causality(modL2, cause="Redd")
```

\$Granger

Granger causality H0: Redd do not Granger-cause Prod Occ

```
data: VAR object modL2
F-Test = 3.452, df1 = 4, df2 = 1464, p-value = 0.008128
```

```
$Instant
```

```
H0: No instantaneous causality between: Redd and Prod Occ
```

```
data: VAR object modL2
Chi-squared = 107.07, df = 2, p-value < 2.2e-16
```

L'analisi dei test di causalità di sistema fornisce una visione chiara delle forti interdipendenze dinamiche:

- **Produzione** → **sistema**: Il test ha un p -value di $1.4e-09$. Rifiutiamo l'ipotesi nulla: la produzione industriale ha un potere predittivo fondamentale sull'andamento congiunto di occupazione e reddito.
- **Occupazione** → **sistema**: Il p -value è $6.046e-08$. Anche in questo caso rifiutiamo l'ipotesi nulla: i livelli occupazionali passati aiutano a prevedere la dinamica futura del sistema.
- **Reddito** → **sistema**: Il p -value è 0.008128, statisticamente significativo al 1%. I ritardi del reddito contribuiscono a spiegare le variazioni di produzione e occupazione.

Tutte e tre le variabili si “causano” a vicenda secondo Granger a livello di sistema. Oltre alla causalità dinamica, i test evidenziano una causalità istantanea estremamente significativa ($p < 2.2e-16$) per tutte le variabili, confermando che gli shock si propagano quasi simultaneamente tra i diversi comparti dell'economia.

Test di Granger (Pairwise)

Mentre il test *causality()* precedente era di sistema (una variabile contro tutte le altre congiuntamente), il test *grangertest()* permette di analizzare le relazioni a coppie in modo più specifico.

Produzione industriale e Occupazione non agricola

```
p = 2 # Numero di lag del modello scelto (modL2)

# Test 1: Occupazione causa produzione?
# H0: Occupazione NON causa la produzione
grangertest(df[, "Prod"] ~ df[, "Occ"], order = p)
```

Granger causality test

```
Model 1: df[, "Prod"] ~ Lags(df[, "Prod"], 1:2) + Lags(df[, "Occ"], 1:2)
Model 2: df[, "Prod"] ~ Lags(df[, "Prod"], 1:2)
      Res.Df Df       F    Pr(>F)
1        490
2        492 -2 17.113 6.544e-08 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# Test 2: La produzione causa occupazione?
# H0: Produzione NON causa occupazione
grangertest(df[, "Occ"] ~ df[, "Prod"], order = p)
```

Granger causality test

```
Model 1: df[, "Occ"] ~ Lags(df[, "Occ"], 1:2) + Lags(df[, "Prod"], 1:2)
Model 2: df[, "Occ"] ~ Lags(df[, "Occ"], 1:2)
      Res.Df Df       F    Pr(>F)
1        490
2        492 -2 24.455 7.526e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Esiti dei test:

- **Test 1 (Occupazione → Produzione):** Il p -value è $6.544e - 08$, quindi statisticamente significativo. Rifiutiamo l'ipotesi nulla e concludiamo che la crescita passata dell'occupazione causa la crescita attuale della produzione.
- **Test 2 (Produzione → Occupazione):** Il p -value è $7.526e - 11$, quindi statisticamente significativo. Rifiutiamo l'ipotesi nulla e concludiamo che esiste una relazione bidirezionale dove anche la crescita passata della produzione causa la crescita attuale dell'occupazione.

Esiste una relazione bidirezionale. Questo nucleo “reale” dell'economia si auto-alimenta: l'output spinge le assunzioni e la nuova forza lavoro sostiene i ritmi produttivi.

Produzione industriale e reddito personale reale

```
# Test 1: Il reddito causa produzione?
# H0: Reddito NON causa la produzione
grangertest(df[, "Prod"] ~ df[, "Redd"], order = p)
```

Granger causality test

```
Model 1: df[, "Prod"] ~ Lags(df[, "Prod"], 1:2) + Lags(df[, "Redd"], 1:2)
```

```
Model 2: df[, "Prod"] ~ Lags(df[, "Prod"], 1:2)
```

	Res.Df	Df	F	Pr(>F)
1	490			
2	492	-2	2.1121	0.1221

```
# Test 2: La produzione causa reddito?  
# H0: Produzione NON causa occupazione  
grangertest(df[, "Redd"] ~ df[, "Prod"], order = p)
```

Granger causality test

```
Model 1: df[, "Redd"] ~ Lags(df[, "Redd"], 1:2) + Lags(df[, "Prod"], 1:2)
```

```
Model 2: df[, "Redd"] ~ Lags(df[, "Redd"], 1:2)
```

	Res.Df	Df	F	Pr(>F)
1	490			
2	492	-2	7.2218	0.0008109 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Esiti dei test:

- **Test 1 (Reddito → Produzione):** Il p -value è 0.1221 , quindi non statisticamente significativo. Non si rifiuta l'ipotesi nulla e concludiamo che la crescita passata del reddito non causa la crescita attuale della produzione.
- **Test 2 (Produzione → Reddito):** Il p -value è 0.0008109, quindi statisticamente significativo. Rifiutiamo l'ipotesi nulla e concludiamo che la crescita passata della produzione causa la crescita attuale del reddito.

La relazione è prevalentemente unidirezionale, è l'attività industriale a generare la ricchezza delle famiglie.

Occupazione non agricola e reddito personale reale

```
# Test 1: Il reddito causa reddito?  
# H0: reddito NON causa l'occupazione  
grangertest(df[, "Occ"] ~ df[, "Redd"], order = p)
```

Granger causality test

```
Model 1: df[, "Occ"] ~ Lags(df[, "Occ"], 1:2) + Lags(df[, "Redd"], 1:2)
Model 2: df[, "Occ"] ~ Lags(df[, "Occ"], 1:2)
      Res.Df Df      F      Pr(>F)
1         490
2         492 -2 10.09 5.077e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# Test 2: Occupazione causa reddito?
# H0: Il occupazione causa il reddito
grangertest(df[, "Redd"] ~ df[, "Occ"], order = p)
```

Granger causality test

```
Model 1: df[, "Redd"] ~ Lags(df[, "Redd"], 1:2) + Lags(df[, "Occ"], 1:2)
Model 2: df[, "Redd"] ~ Lags(df[, "Redd"], 1:2)
      Res.Df Df      F Pr(>F)
1         490
2         492 -2 0.268 0.765
```

Esiti dei test:

- **Test 1 (Reddito $\rightarrow$ Occupazione):** Il p -value è $5.077e - 05$, quindi statisticamente significativo. Non si rifiuta l'ipotesi nulla e concludiamo che la crescita passata del reddito causa la crescita attuale dell'occupazione.
- **Test 2 (Occupazione $\rightarrow$ Reddito):** Il p -value è molto alto 0.765 , quindi non statisticamente significativo. Rifiutiamo l'ipotesi nulla e concludiamo che la crescita passata dell'occupazione non causa la crescita attuale del reddito.

Emerge una chiara relazione unidirezionale dove l'occupazione guida il reddito. La crescita salariale aggregata dipende quindi strettamente dall'espansione del mercato del lavoro.

Analisi economica del sistema

L'integrazione tra le funzioni di cross-correlazione e i test di Granger permette di tracciare una mappa precisa della trasmissione degli impulsi economici:

La Produzione Industriale si conferma come il motore primario dell'economia. Le CCF mostrano che essa anticipa l'occupazione (ritardo negativo significativo), e i test di Granger

validano un legame bidirezionale: fabbriche e posti di lavoro operano in simbiosi, creando un nucleo produttivo reattivo.

La ricchezza si trasmette poi lungo una catena lineare: la produzione genera il reddito, ma lo fa principalmente attraverso il canale dell'occupazione. I test pairwise chiariscono infatti che è l'occupazione a causare il reddito e non viceversa. Questo suggerisce che il benessere delle famiglie non aumenta autonomamente, ma è l'esito finale di un processo che parte dal settore industriale e passa per il mercato del lavoro.

In sintesi, emerge un circolo virtuoso dove la produzione industriale innesca il ciclo, l'occupazione lo consolida e lo trasforma in reddito distribuito. Sebbene il reddito a livello di sistema mostri un feedback verso le altre variabili (sostenendo la domanda), la struttura portante dell'economia analizzata poggia sulla capacità del settore produttivo di generare impiego, rendendo ogni anello della catena indispensabile per trasformare la crescita industriale in benessere diffuso.

Impulse Response Function (IRF)

Si procede ora con l'analisi degli effetti di uno shock. Utilizziamo la Funzione di Risposta all'Impulso (IRF) ortogonalizzata tramite la decomposizione di Cholesky.

La decomposizione di Cholesky è sensibile all'ordine delle variabili. Si è scelto l'ordine:

1. Produzione Industriale
2. Occupazione non agricola
3. Reddito personale reale

Questo impone la seguente assunzione economica:

- Uno shock contemporaneo alla produzione industriale può influenzare nello stesso mese produzione, occupazione e reddito.
- Uno shock contemporaneo all'occupazione può influenzare l'occupazione e reddito personale, ma non la produzione.
- Uno shock contemporaneo al reddito personale può influenzare solo sé stesso.

Si è scelto l'ordine Produzione → Occupazione → Reddito seguendo la logica della catena di trasmissione del valore. La Produzione Industriale è identificata come la variabile più esogena (motore del ciclo), mentre il reddito personale reale è la variabile più endogena, che recepisce gli shock provenienti sia dal settore produttivo che dal mercato del lavoro nello stesso periodo di riferimento.

```

irf_chol = irf(modL2,
               impulse = c("Prod", "Occ", "Redd"),
               response = c("Prod", "Occ", "Redd"),
               n.ahead = 12, boot = TRUE, ortho = TRUE, runs = 1000)
par(mfrow = c(3,3))
plot(irf_chol, plot.type = "single")

```




Figure 25: Funzione di Risposta all'Impulso (IRF) ortogonalizzata VAR(2): ordine Produzione, Occupazione e Reddito.

L'analisi delle Funzioni di Risposta all'Impulso (IRF), dove le righe indicano la variabile che subisce lo shock (Impulso) e le colonne la variabile che reagisce (Risposta), conferma la dinamica ciclica e la gerarchia temporale del sistema:

- **Prima Riga (Shock alla Produzione Industriale):** Uno shock positivo alla produzione ha un effetto immediato, positivo e statisticamente significativo su tutte le variabili del sistema. Come previsto, l'espansione industriale “trascina” istantaneamente sia l'occupazione (grafico in alto-centro) che il reddito personale (grafico in alto-destra), a conferma del ruolo della produzione come motore trainante dell'economia. L'effetto tende a riassorbirsi rapidamente entro i primi 3 – 4 mesi, coerentemente con la stabilità del modello VAR rilevata in precedenza.
- **Seconda Riga (Shock all'Occupazione):** Uno shock positivo e inatteso all'occupazione genera una risposta positiva e significativa sul reddito (grafico centro-destra), riflettendo l'immediato aumento della massa salariale. Tuttavia, come imposto dall'ordine di Cholesky, lo shock non ha un effetto positivo immediato sulla produzione (grafico centro-sinistra); al contrario, si osserva una successiva contrazione tecnica della produzione e del reddito stesso intorno al secondo mese, suggerendo un meccanismo di aggiustamento ciclico del mercato del lavoro.
- **Terza Riga (Shock al Reddito Personale Reale):** Uno shock “puro” al reddito, non derivante da produzione o lavoro, mostra un impatto limitato e breve. Si registra una risposta positiva e significativa sulla produzione industriale e sull'occupazione (grafici in basso-sinistra e centro) al primo mese, confermando il feedback della domanda rilevato dai test di Granger: un aumento della ricchezza percepita stimola temporaneamente l'attività produttiva e la richiesta di lavoro.

In sintesi, i grafici confermano che il sistema reagisce con estrema rapidità agli impulsi. La forte significatività degli impatti al tempo zero (Lag 0) valida la scelta di utilizzare una decomposizione di Cholesky per isolare gli shock.

Data la forte correlazione contemporanea residua rilevata in precedenza, verifichiamo quanto le risposte alle funzioni ad impulsi siano sensibili all'ordine delle variabili nella decomposizione di Cholesky.

Nel modello base si è assunto che la produzione fosse la variabile più esogena. Qui invertiamo l'ordine, assumendo che gli shock partano dall'occupazione seguiti del reddito e infine dalla produzione.

```
# Creazione di un nuovo dataset con ordine invertito
df_new = df[, c("Redd", "Occ", "Prod")]

# Ri-stima del modello con il nuovo ordine
modL2_new = vars::VAR(df_new, p = 2, type = "const")

# Calcolo delle nuove IRF
irf_new = irf(modL2_new,
               n.ahead = 12, boot = TRUE, ortho = TRUE, runs = 1000)
```

```
# Grafico
par(mfrow = c(3,3))
plot(irf_new,plot.type = "single")
```




Figure 26: Funzione di Risposta all'Impulso (IRF) ortogonalizzata VAR(2): ordine Reddito, Occupazione e Produzione.

Il test di sensibilità conferma la robustezza del modello. Sebbene i p -value di causalità istantanea indicassero un'elevata sincronia, la persistenza e la direzione delle risposte non cambiano drasticamente con l'ordine delle variabili.

Si mantenere per l'analisi principale l'ordine $\text{Prod} \rightarrow \text{Occ} \rightarrow \text{Redd}$, poiché meglio riflette la gerarchia decisionale delle imprese e la sequenza temporale osservata nei cross-correlogrammi, dove la produzione industriale funge da innesco ciclico primario.

Forecast Error Variance Decomposition (FEVD)

L'analisi della FEVD (Decomposizione della Varianza dell'Errore di Previsione) è complementare alle IRF. Dice quanta parte dell'incertezza futura (la varianza dell'errore di previsione) di una variabile è spiegata dagli shock “propri” rispetto a quelli provenienti dalle altre variabili del sistema. Anche questa analisi dipende dall'ordine di Cholesky scelto.

```
fevd_us = fevd(modL2, n.ahead = 12)
plot(fevd_us)
```




Figure 27: Decomposizione della Varianza dell'Errore di Previsione VAR(2).

I grafici mostrano la scomposizione percentuale della varianza dell'errore di previsione per le tre variabili fino a 12 mesi nel futuro, confermando la struttura di interdipendenza rilevata nelle analisi precedenti.

- **FEVD per la produzione:** La varianza dell'errore di previsione della produzione industriale è spiegata quasi esclusivamente da shock propri (area grigio scuro), che pesano per oltre il 95% lungo tutto l'orizzonte temporale considerato. Il contributo di Occupazione e Reddito è pressoché nullo. Questo risultato conferma che la Produzione si comporta come la variabile più esogena del sistema: la sua incertezza futura è guidata quasi esclusivamente dalla sua stessa dinamica interna.
- **FEVD per l'occupazione:** L'incertezza nell'occupazione è spiegata da due forze principali di simile entità. Fin dal primo mese, circa il 50% dell'errore di previsione è attribuibile a shock alla produzione, mentre il restante 50% è spiegato da shock all'occupazione stessa. Il ruolo del Reddito rimane trascurabile. Questo equilibrio sottolinea la fortissima dipendenza del mercato del lavoro dai cicli industriali, coerentemente con l'elevata correlazione contemporanea osservata.
- **FEVD per il Reddito Personale Reale:** L'incertezza del reddito personale reale mostra una scomposizione più articolata. Sebbene la componente prevalente sia legata agli shock propri (circa il 70%), una quota significativa della varianza (circa il 20%) è spiegata costantemente dagli shock alla produzione e, in misura minore (circa il 10%), da quelli all'occupazione. Questo conferma che il reddito delle famiglie è, in ultima istanza, un ricettore degli impulsi che partono dal settore reale dell'economia.

La FEVD conferma pienamente la struttura gerarchica ipotizzata con l'ordine di Cholesky ($\text{Prod} \rightarrow \text{Occ} \rightarrow \text{Redd}$). La Produzione Industriale emerge come il motore dominante, i cui shock spiegano una quota rilevante dell'incertezza futura di Occupazione e Reddito, validando empiricamente la catena di trasmissione che parte dalle fabbriche per arrivare alle tasche dei cittadini.

Modello a funzione di trasferimento (TFM)

Dopo aver analizzato le interdipendenze dinamiche e i meccanismi di feedback attraverso il modello VAR, approfondiamo la relazione specifica tra reddito personale reale e Produzione Industriale utilizzando un approccio a Funzione di Trasferimento (TFM).

Inquadramento Teorico e Scelta delle Variabili

La scelta di focalizzare l'analisi su queste due serie risiede nei risultati dei test di causalità di Granger e nelle dinamiche rilevate a livello di sistema. Mentre la produzione industriale funge da innesco del ciclo economico, i test hanno evidenziato come il reddito eserciti un'influenza significativa sulla produzione, agendo da segnale di domanda per le imprese. In questo contesto:

- Il reddito personale reale funge da variabile di input.
- La produzione industriale rappresenta la variabile di output (dipendente).

Il modello a funzione di trasferimento permette di modellare esplicitamente come una variazione nel potere d'acquisto delle famiglie si “trasferisca” nel tempo sui livelli produttivi delle fabbriche. Questo approccio consente di distinguere tra l'impatto immediato dello shock di reddito e gli effetti ritardati, catturando la velocità con cui il sistema industriale reagisce ai mutamenti della domanda aggregata.

Prewhitening e CCF sui residui

```
# Serie input sbiancata dall'autocorrelazione
alfa = df[,3]

# Applicato stesso filtro dell'input all'output
# (solo differenziazione)
beta = df[,1]

ccf(beta, alfa, lag.max = 10, main = "CCF(beta, alfa)")
```




Figure 28: Funzione di cross-correlazione tra serie output e input filtrate con il filtro per l'input.

Dall'analisi della funzione di cross-correlazione tra i residui pre-sbiancati emerge un chiaro picco al lag 0, che identifica $b = 0$. Il successivo decadimento dei coefficienti suggerisce una componente inerziale nel processo di trasferimento, portando all'identificazione di un termine

al denominatore ($r = 1$). La mancanza di ulteriori picchi significativi nei lag positivi immediati permette di impostare il numeratore a $s = 0$. Questa struttura $(0, 0, 1)$ descrive un sistema in cui le variazioni dell'occupazione hanno un impatto immediato sulla produzione, i cui effetti persistono parzialmente nel tempo prima di esaurirsi.

Stima del modello

```
# MTS::tfm1(y, x, orderN = c(p,d,q), orderX = c(r,s,b))  
m.1 = MTS::tfm1(df[,1], df[,3], orderN = c(0,0,0), orderX = c(1,0,0))
```

```
Warning in nlm(Nlike, par, hessian = TRUE, dY = dY, dX = dX, orderN = orderN, :  
NA/NaN replaced by maximum positive value
```

```
Delay: 0  
Transfer function coefficients & s.e.:  
in the order: constant, omega, and delta: 1 1 1  
      [,1] [,2] [,3]  
v    -0.0979 0.6975 0.3398  
se.v  0.0456 0.0536 0.0584
```

```
residui = ts(m.1$residuals, frequency = 12, start = c(1980,2))  
ccf(alfa, residui, main = "CCF(alfa, residui m.1)")
```




Figure 29: Funzione di cross-correlazione tra serie dei residui del primo modello stimato e l'input.

```
par(mfcol = c(2,1))  
acf(residui, main = "ACF residui modello")  
pacf(residui, main = "PACF residui modello")
```




Figure 30: Funzione d'autocorrelazione globale e parziale dei residui del primo modello stimato.

I residui mostrano correlazione seriale quindi è opportuno modellare anche la parte di disturbo η_t del modello a funzione di trasferimento.

```
m.2 = MTS::tfm1(df[,1], df[,3], orderN = c(1,0,0), orderX = c(1,0,0))
```

```
Warning in nlm(Nlike, par, hessian = TRUE, dY = dY, dX = dX, orderN = orderN, :
NA/NaN replaced by maximum positive value
```

```
Delay: 0
Transfer function coefficients & s.e.:
in the order: constant, omega, and delta: 1 1 1
      [,1] [,2] [,3]
v    -0.0951 0.6702 0.3556
```

```
se.v 0.0511 0.0548 0.0618
ARMA order:
[1] 1 0 0
ARMA coefficients & s.e.:
      [,1]
coef.arma 0.1168
se.arma    0.0456
```

```
residui2 = ts(m.2$residuals,frequency = 12,start = c(1980,2))
```

```
par(mfcol = c(2,1))
acf(residui2, main = "ACF residui modello")
pacf(residui2, main = "PACF residui modello")
```




Figure 31: Funzione d'autocorrelazione globale e parziale dei residui del secondo modello stimato.

```
Box.test(residui2,lag=24,type = "Ljung")
```

Box-Ljung test

```
data: residui2  
X-squared = 29.265, df = 24, p-value = 0.2103
```

Provando diverse specificazione del modello a funzione di trasferimento non si notato miglioramenti, quindi nonostante la permanenza di alcuni picchi marginalmente superiori alle bande di confidenza nella CCF (valori inferiori a 0.15), si è scelto di mantenere lo stesso il modello. La validità del modello è confermata dal test di Ljung-Box sui residui (che non permette di rifiutare l'ipotesi di incorrelazione) e dalla significatività dei parametri.

ARIMAX

Si procede con l'adattamento di un modello ARIMAX che rappresenta una versione più sofisticata di un classico modello univariato ARIMA dove vengono aggiunte come variabili esogene l'occupazione non agricola e il reddito personale reale.

```
require(forecast)  
y = df[,1]  
X = df[,c(2,3)]  
# y = produzione industriale, x1 = occupazione non agricola  
# x2 = reddito personale reale  
fit.Arimax = auto.arima(y, xreg = X,seasonal = FALSE)  
summary(fit.Arimax)
```

```
Series: y  
Regression with ARIMA(4,0,2) errors
```

```
Coefficients:  
          ar1      ar2      ar3      ar4      ma1      ma2      Occ      Redd  
          1.0661 -0.7337 -0.0454  0.1171 -1.0496  0.8340  1.0272  0.1193  
s.e.    0.2296   0.2133   0.0748  0.0529   0.2255  0.2061  0.0491  0.0467
```

```
sigma^2 = 0.4095: log likelihood = -479.41  
AIC=976.82   AICc=977.19   BIC=1014.7
```

```
Training set error measures:
```

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.00530026	0.6347555	0.439173	108.6084	223.6807	0.5476131
	ACF1					
Training set	-0.004069772					

Struttura del Modello

Componente rumore

Il modello selezionato è un ARIMA(4,0,2) applicato ai residui della regressione.

Componente Autoregressiva: La forte significatività dei parametri AR indica che la produzione industriale possiede un'elevata persistenza e dipende fortemente dai propri livelli passati.

Media Mobile: I termini MA suggeriscono che il sistema reagisce in modo articolato agli shock casuali di breve periodo, “smussando” le fluttuazioni inattese per ritornare verso il trend determinato dalle esogene.

Analisi delle Variabili Esogene

A differenza del TFM o del VAR, l'ARIMAX qui stimato quantifica l'impatto contemporaneo delle esogene sulla produzione:

Occupazione: Il coefficiente 1.0253 è statisticamente significativo (il rapporto tra stima e errore standard è circa 21.7).

Reddito: Il coefficiente 0.1352 è positivo e significativo (il rapporto tra stima e errore standard è circa 3.06).

Previsioni

L'attenzione si sposta dall'analisi strutturale alla valutazione delle performance previsive, con l'obiettivo di determinare quale approccio metodologico offra la migliore capacità di anticipare l'andamento della produzione industriale. La scelta di focalizzare il confronto sulla produzione industriale come variabile dipendente non è casuale, ma risiede nel suo ruolo di “motore” del ciclo economico emerso nelle analisi precedenti. La sua natura dinamica permette di testare se i modelli multivariati siano effettivamente in grado di catturare la complessità degli shock reali meglio di un approccio isolato.

La valutazione verrà effettuata mettendo a confronto quattro diverse classi di modelli, caratterizzate da un crescente livello di complessità informativa:

- **Modello Univariato:** Rappresentato da un processo ARIMA, questo approccio si basa esclusivamente sull'inerzia e sulla storia passata della serie stessa, ignorando qualsiasi interazione esterna.
- **Modello ARIMAX:** Un'estensione del modello univariato che include come variabili esogene esterne sia l'occupazione che il reddito. Questo modello permette di valutare l'impatto contemporaneo delle spinte del lavoro e della domanda sulla produzione.
- **Funzione di Trasferimento (TFM):** Un approccio ibrido che modella specificamente come gli shock di una variabile di input (l'Occupazione) si distribuiscano e si trasferiscano nel tempo sulla variabile di output, integrando una componente di disturbo stocastico.
- **Vector Autoregression (VAR):** Un modello multivariato che cattura le interdipendenze e i meccanismi di feedback simultanei tra Produzione, Occupazione e Reddito, trattando tutte le variabili come endogene.

La metodologia adottata prevede la suddivisione dei dati in un insieme di stima, utilizzato per adattare i modelli, e un insieme di test, necessario per verificarne la reale capacità predittiva su dati non osservati, evitando problemi di sovradattamento. Tutte le previsioni verranno effettuate sulle serie espresse in log-differenze prime, focalizzando l'analisi sulla capacità di anticipare i tassi di crescita e la volatilità del sistema.

Per rendere la valutazione robusta, verrà utilizzato un approccio a finestra mobile con previsione a un passo ($h = 1$). Questa tecnica permette di aggiornare i parametri dei modelli man mano che nuove informazioni diventano disponibili, riflettendo meglio la capacità di adattamento dei modelli ai mutamenti strutturali. Infine, la precisione dei forecast verrà quantificata tramite gli indicatori MSE (Mean Square Error) e MAE (Mean Absolute Error). Per stabilire se le differenze nelle performance siano statisticamente rilevanti e non dovute al caso, verrà applicato il test di Diebold-Mariano, confrontando i vari modelli adattati.

Calcolo previsioni nell'insieme di stima

```
stima = window(dati_trasf, end = c(2021, 6))
test = window(dati_trasf, start = c(2021, 7))

n_total = nrow(dati_trasf)
n_test = nrow(test)
train_end = n_total - n_test

# Ordini TFM (identificati da analisi teorica)
b = 0 # ritardo minimo input
s = 0 # grado numeratore
r = 1 # grado denominatore (risposta interna)
```

```

d_tfm = 0 # differenza input
p_tfm = 0 # AR del rumore
q_tfm = 1 # MA del rumore

# Mapping TFM → ARIMAX stabile
AR_eq = r + p_tfm # AR totale
I_eq = d_tfm # differencing
MA_eq = r + q_tfm # MA totale

# Serie reale di confronto (Produzione Industriale)
actual_prod = test[,1]

# --- Inizializzazione Vettori ---
pred_arima      = numeric(n_test)
pred_arimax_expost = numeric(n_test) # Con esogene REALI
pred_arimax_exante = numeric(n_test) # Con esogene PREVISTE
pred_tfm        = numeric(n_test)
pred_var_statico = numeric(n_test)
pred_var_dim     = numeric(n_test)
pred_vecm        = numeric(n_test)

# Loop Finestra Mobile
for(i in 1:n_test) {

  # 1. Definizione finestra corrente
  current_train = dati_trasf[i:(train_end + i - 1), ]

  # -----
  # A. PREPARAZIONE ESOGENE
  # -----

  # Scenario 1: EX-ANTE (Previsione Realistica)
  # Si prevedono le esogene usando solo il passato disponibile
  fit_occ_exog = forecast::auto.arima(current_train[,2])
  pred_occ_val = forecast::forecast(fit_occ_exog, h = 1)$mean

  fit_redd_exog = forecast::auto.arima(current_train[,3])
  pred_redd_val = forecast::forecast(fit_redd_exog, h = 1)$mean

  xreg_future_exante = matrix(c(pred_occ_val, pred_redd_val), nrow = 1)
  colnames(xreg_future_exante) = c("Occ", "Redd")
}

```

```

# Scenario 2: EX-POST (Analisi di Scenario)
xreg_future_expost = matrix(dati_trasf[train_end + i, c(2,3)], nrow = 1)
colnames(xreg_future_expost) = c("Occ", "Redd")

# -----
# B. STIMA E PREVISIONE MODELLI
# -----

# per VECM
current_train_lev = window(Log.Serie,
                           start = time(Log.Serie)[i],
                           end = time(Log.Serie)[train_end + i - 1])

# --- 1. ARIMA Univariato ---
fit_arima = forecast::auto.arima(current_train[,1])
pred_arima[i] = forecast::forecast(fit_arima, h = 1)$mean

# --- 2. ARIMAX (Doppia Previsione) ---
fit_arimax = forecast::auto.arima(current_train[,1],
                                   xreg = current_train[,c(2,3)])

# Previsione EX-ANTE (Confrontabile con VAR)
pred_arimax_exante[i] = forecast::forecast(fit_arimax,
                                           xreg = xreg_future_exante, h = 1)$mean

# Previsione EX-POST (Benchmark teorico ideale)
pred_arimax_expost[i] = forecast::forecast(fit_arimax,
                                           xreg = xreg_future_expost, h = 1)$mean

# --- 3. TFM (Si usa solo con esogene note) ---
fit_tfm = forecast::Arima(current_train[,1],
                          order = c(AR_eq, I_eq, MA_eq),
                          xreg = current_train[,2], include.mean = TRUE)
pred_tfm[i] =
  as.numeric(forecast::forecast(fit_tfm,
                              h = 1,
                              xreg = xreg_future_expost[,2])$mean)

# --- 4. VAR(2)-Statico ---
fit_var_s = vars::VAR(current_train, p = 2, type = "const")
pred_var_statico[i] = predict(fit_var_s, n.ahead = 1)$fcst$Prod[1,1]

```

```

# --- 5. VAR(2)-Dinamico ---
lag_select = vars::VARselect(current_train, lag.max = 12, type = "both")
K_opt = lag_select$selection['SC(n)']
if(is.na(K_opt) || K_opt < 1) K_opt = 1
fit_var_d = vars::VAR(current_train, p = K_opt, type = "const")
pred_var_dim[i] = predict(fit_var_d, n.ahead = 1)$fcst$Prod[1,1]

# --- 6. VECM ---
jo_test = urca::ca.jo(current_train_lev, type = "trace",
                      ecdet = "const", K = 2, spec = "longrun")
fit_vecm_var = vars::vec2var(jo_test, r = 1)
fcast_vecm = predict(fit_vecm_var, n.ahead = 1)
last_obs_log = tail(current_train_lev[,1], 1)
pred_log_lev = fcast_vecm$fcst$Prod[1,1]
pred_vecm[i] = (pred_log_lev - last_obs_log) * 100
}

```

Valori stimati dai modelli nell'insieme di stima

```

require(ggplot2)
require(tidyr)
require(zoo)
require(scales)

# -----
# Estrazione dei Valori stimati sui Log-Diff perc
# -----
# Ri-stima dei modelli sull'intero set 'stima'
fit_arma_in <- forecast::auto.arima(stima[,1])
fit_arimax_in <- forecast::auto.arima(stima[,1], xreg = stima[,c(2,3)])
fit_var_in <- vars::VAR(stima, p = 2, type = "const")
fit_tfm_in <- forecast::Arima(stima[,1],
                             c(AR_eq, I_eq, MA_eq), xreg = stima[,2])

# Si recuperano i log-livelli corrispondenti al periodo di 'stima'
stima_lev <- window(Log.Serie, end = c(2021, 6))
fit_jo_in <- ca.jo(stima_lev, type = "trace",
                  ecdet = "const", K = 2, spec = "longrun")
fit_vecm_in <- vec2var(fit_jo_in, r = 1)

```

```

# Estrazione fit (tassi di crescita)
fitted_arma <- as.numeric(fitted(fit_arma_in))
fitted_arimax <- as.numeric(fitted(fit_arimax_in))
fitted_tfm <- as.numeric(fitted(fit_tfm_in))
fitted_var <- as.numeric(fitted(fit_var_in)[,1])

# Estrazione fit VECM: essendo in livelli, si calcola la diff logaritmica
# fitted(fit_vecm_in) restituisce i log-livelli stimati
fitted_vecm_lev <- fitted(fit_vecm_in)[,1]
# Si calcola il tasso di crescita stimato (log_y_t - log_y_t-1) * 100
# Per allineare, si perdono i primi K ritardi (K=2)
fitted_vecm <- diff(fitted_vecm_lev) * 100

# Allineamento temporale (il VAR(2) e VECM perdono i primi punti)
n_stima <- nrow(stima)
idx_ref <- 3:n_stima

# -----
# Trasformazione ai Livelli (In-Sample)
# -----
actual_levels_in <- as.numeric(Serie[idx_ref])
prev_levels_in <- as.numeric(Serie[idx_ref - 1])

lev_fit_arma <- prev_levels_in * exp(fitted_arma[idx_ref] / 100)
lev_fit_arimax <- prev_levels_in * exp(fitted_arimax[idx_ref] / 100)
lev_fit_tfm <- prev_levels_in * exp(fitted_tfm[idx_ref] / 100)
lev_fit_var <- prev_levels_in * exp(fitted_var / 100)
lev_fit_vecm <- prev_levels_in * exp(fitted_vecm / 100) # Aggiunto VECM

# -----
# Visualizzazione Grafica delle stime
# -----
plot_data_in <- data.frame(
  Tempo = as.Date(zoo::as.yearmon(time(stima)[idx_ref])),
  Reale = actual_levels_in,
  ARIMA = lev_fit_arma,
  ARIMAX = lev_fit_arimax,
  TFM = lev_fit_tfm,
  VAR = lev_fit_var,
  VECM = lev_fit_vecm # Aggiunto VECM
)

```

```

# -----
# Preparazione Dati (Filtro dal 2000)
# -----
data_inizio <- as.Date("2000-01-01")
plot_data_2000 <- plot_data_in[plot_data_in$Tempo >= data_inizio, ]

modelli <- c("ARIMA", "ARIMAX", "TFM", "VAR", "VECM")
colori <- c("ARIMA" = "blue", "ARIMAX" = "red",
            "TFM" = "darkgreen", "VAR" = "purple", "VECM" = "brown")

# -----
# Loop per generare i grafici singoli
# -----
for (mod in modelli) {
  p <- ggplot(plot_data_2000, aes(x = Tempo)) +
    geom_line(aes(y = Reale, linetype = "Osservato"),
              color = "black", size = 0.8) +
    geom_line(aes_string(y = mod, color = shQuote(mod),
                        linetype = shQuote("Stimato")),
              size = 0.8) +
    scale_x_date(date_breaks = "2 years", date_labels = "%Y") +
    scale_color_manual(values = colori) +
    scale_linetype_manual(values = c("Osservato" = "solid",
                                    "Stimato" = "dashed")) +
    labs(title = paste("Bontà di Adattamento nell'insieme di stima:", mod),
         subtitle = "Confronto tra dati osservati e valori stimati dal 2000",
         x = "Anno", y = "Indice Produzione",
         color = "Modello", linetype = "Legenda") +
    theme_minimal() +
    theme(legend.position = "bottom",
          axis.text.x = element_text(angle = 45, hjust = 1))
  print(p)
}

```




Figure 32: Confronto tra valori osservati e stimati nell'insieme di stima.




Figure 33: Confronto tra valori osservati e stimati nell'insieme di stima.




Figure 34: Confronto tra valori osservati e stimati nell'insieme di stima.




Figure 35: Confronto tra valori osservati e stimati nell'insieme di stima.




Figure 36: Confronto tra valori osservati e stimati nell'insieme di stima.

I grafici mostrano una buona bontà di adattamento confermano la solidità della stima, tutti i modelli replicano fedelmente la storia della produzione industriale, ma con qualche leggera differenza. L'ARIMA si dimostra un benchmark affidabile nel seguire il trend, pur apparendo leggermente meno reattivo di fronte a shock improvvisi. Il VAR è il modello più aderente in assoluto, ma questa estrema vicinanza ai dati suggerisce un possibile *sovradattamento*, il sistema insegue anche il "rumore" della serie.

Visualizzazione grafica delle previsioni

```
# -----
# Visualizzazione Grafica Previsioni
# -----
# -----
# Inversione della Trasformazione (da Log-Diff*100 a Livelli)
# -----
back_to_levels <- function(pred_log_diff_100, start_value) {
  pred_log_diff <- pred_log_diff_100 / 100
  # Calcola i logaritmi cumulati:  $\log(y_t) = \log(y_0) + \text{sum}(\text{delta\_log\_y})$ 
  log_levels <- log(start_value) + cumsum(pred_log_diff)
  return(exp(log_levels))
}
```

```

}
# -----
# Preparazione Dati Storici (Stima)
# -----
# ultimi 96 mesi
n_hist <- 96
hist_idx <- (train_end - n_hist + 1):train_end

df_hist <- data.frame(
  Tempo = as.Date(zoo::as.yearmon(time(Serie)[hist_idx])),
  Livello = as.numeric(Serie[hist_idx]),
  Modello = "Storico"
)
# -----
# Preparazione Previsioni e Valori Reali (Test)
# -----
last_train_level = Serie[train_end,1]
lev_actual = Serie[(train_end + 1):n_total]
lev_arima = back_to_levels(pred_arima, last_train_level)
lev_arimax = back_to_levels(pred_arimax_expost, last_train_level)
lev_arimax_eso_prev = back_to_levels(pred_arimax_exante, last_train_level)
lev_tfm = back_to_levels(pred_tfm, last_train_level)
lev_varS = back_to_levels(pred_var_statico, last_train_level)
lev_varD = back_to_levels(pred_var_dim, last_train_level)
lev_vecm = back_to_levels(pred_vecm, last_train_level) # Aggiunto VECM

plot_data_test <- data.frame(
  Tempo = as.Date(zoo::as.yearmon(time(test))),
  Reale = as.numeric(lev_actual),
  ARIMA = as.numeric(lev_arima),
  ARIMAX = as.numeric(lev_arimax),
  ARIMAX_Eso_prev = as.numeric(lev_arimax_eso_prev),
  TFM = as.numeric(lev_tfm),
  VAR_S = as.numeric(lev_varS),
  VAR_D = as.numeric(lev_varD),
  VECM = as.numeric(lev_vecm)
)

plot_long_test <- pivot_longer(plot_data_test, cols = -Tempo,
                               names_to = "Modello",
                               values_to = "Livello")

```

```

# Unione stima + Test
plot_final <- rbind(df_hist, plot_long_test)
# -----
# Visualizzazione Grafica Completa
# -----
ggplot(plot_final, aes(x = Tempo, y = Livello,
                      color = Modello, linetype = Modello)) +
  geom_line(size = 0.6) +
  geom_point(data = subset(plot_final,
                          Modello %in% c("Storico", "Reale")),
            size = 0.8, alpha = 0.5) +
  geom_vline(xintercept = as.numeric(as.Date(zoo::as.yearmon(
    time(Serie)[train_end]))),
            linetype = "dotted", color = "gray40", size = 0.6) +
  annotate("text", x = as.Date(zoo::as.yearmon(time(Serie)[train_end])),
            y = max(plot_final$Livello), label = "Inizio Test",
            hjust = 1.1, vjust = 1, size = 3, color = "gray40") +
  scale_x_date(
    breaks = scales::breaks_pretty(n = 8),
    labels = scales::label_date_short()
  ) +
  scale_color_manual(values = c("Storico" = "black", "Reale" = "black",
                                "ARIMA" = "blue", "ARIMAX" = "red",
                                "TFM" = "darkgreen", "VAR_S" = "purple",
                                "VAR_D" = "gold", "VECM" = "brown",
                                "ARIMAX_Eso_prev" = "green")) +
  scale_linetype_manual(values = c("Storico" = "solid", "Reale" = "solid",
                                   "ARIMA" = "solid", "ARIMAX" = "solid",
                                   "TFM" = "solid", "VAR_S" = "solid",
                                   "VAR_D" = "solid", "VECM" = "solid",
                                   "ARIMAX_Eso_prev" = "solid")) +
  labs(title = "Previsioni insieme di test e Dati Storici",
       subtitle = "Produzione Industriale: Livelli originali",
       x = "Tempo", y = "Indice Produzione") +
  theme_minimal() +
  theme(legend.position = "bottom",
        axis.ticks.x = element_line(color = "black"),
        panel.grid.minor = element_blank())

```




Figure 37: Confronto tra valori osservati e previsti dell'insieme di verifica per i modelli adattati nell'insieme di stima.

L'analisi del grafico delle previsioni dell'insieme di test permette di valutare la capacità dei modelli di anticipare la dinamica reale della produzione industriale in un orizzonte temporale non osservato durante la stima.

Dall'osservazione visiva del grafico, si possono trarre le seguenti conclusioni:

- **Comportamento ARIMA:** La previsione dell'ARIMA (linea blu tratteggiata) mostra una tendenza alla crescita costante, faticando a catturare le oscillazioni di breve periodo della serie reale.
- **Performance dei Modelli Multivariati (ARIMAX e TFM):**
 - L'ARIMAX (linea rossa) tende a sovrastimare i livelli di produzione nell'ultima parte del campione, pur avendo mostrato un'ottimo adattamento nell'insieme di stima.
 - L'ARIMAX con le variabili esogene stimate tramite un ARIMA (linea verde chiaro) tende seguire l'adamento del VECM e si nota una chiara differenza tra le stime con le variabili esogene note e stimate.
 - Il TFM (linea verde) sembra seguire una traiettoria più vicina a quella reale nella prima fase, per poi divergere verso l'alto insieme all'ARIMA.

- **Modelli VAR (Statico e Dinamico):**

- Il VAR **statico** (linea viola) mostra una chiara tendenza alla sottostima sistematica, posizionandosi stabilmente al di sotto della serie reale.
- Il VAR **dinamico** (linea gialla), sembra essere il modello che prevede meglio l'andamento della produzione industriale dell'insieme di stima, si nota però che le previsioni hanno una variabilità maggiore rispetto ad altri modelli adattati.

- **Modello VECM:**

- **Performance del VECM (linea marrone):** La traiettoria del modello VECM si posiziona in un'area intermedia del grafico. Coerentemente con quanto emerso dall'analisi dei coefficienti di aggiustamento (α), il modello non mostra un "richiamo" verso l'equilibrio di lungo periodo sufficientemente forte da divergere drasticamente dagli altri modelli multivariati.
- **Confronto VECM vs VAR:** È interessante notare come il VECM, pur incorporando la relazione di cointegrazione, non riesca a migliorare significativamente il VAR dinamico in questo specifico orizzonte di test. Ciò conferma che, per le serie analizzate, le dinamiche di breve periodo sono predominanti rispetto ai meccanismi di riequilibrio strutturale di lungo periodo.

Errori di previsione e metriche

```
# -----  
# Calcolo dei vettori di errore  
# -----  
  
e_arima <- actual_prod - pred_arima  
e_arimax <- actual_prod - pred_arimax_expost  
e_arimax_esog_prev <- actual_prod - pred_arimax_exante  
e_tfm <- actual_prod - pred_tfm  
e_var_s <- actual_prod - pred_var_statico  
e_var_d <- actual_prod - pred_var_dim  
e_VECM <- actual_prod - pred_vecm  
  
par(mfrow=c(3,3))  
plot(density(e_arima),main="ARIMA")  
plot(density(e_arimax),main="ARIMAX")  
plot(density(e_arimax_esog_prev),main="ARIMAX - Con esogene previste")  
plot(density(e_tfm),main="TFM")  
plot(density(e_var_s),main="VAR-Statico")
```

```

plot(density(e_var_d),main="VAR-Dinamico")
plot(density(e_VECM),main="VECM")

Lista_errori <- list(
  ARIMA = e_arima,
  ARIMAX = e_arimax,
  ARIMAX_Eso_Prev = e_arimax_esog_prev,
  TFM = e_tfm,
  VAR_S = e_var_s,
  VAR_D = e_var_d,
  VECM = e_VECM
)

# -----
# Calcolo dei vettori di errore assoluti
# -----
Lista_errori_abs <- list(
  ARIMA = abs(e_arima),
  ARIMAX = abs(e_arimax),
  ARIMAX_Eso_Prev = abs(e_arimax_esog_prev),
  TFM = abs(e_tfm),
  VAR_S = abs(e_var_s),
  VAR_D = abs(e_var_d),
  VECM = abs(e_VECM)
)

# -----
# Funzione per le statistiche descrittive degli errori
# -----

calc_stats <- function(x) {
  c(
    Mediana = median(x, na.rm = TRUE),# Indice di posizione più robusto
    Varianza = var(x, na.rm = TRUE), # Variabilità dell'errore
    Dev_Std = sd(x, na.rm = TRUE) # Volatilità dell'errore
  )
}

# -----
# Creazione del Dataframe finale
# -----

```

```
df_stats_errori <- as.data.frame(t(apply(Lista_errori_abs, calc_stats)))

df_stats_errori <- round(df_stats_errori, 4)
print(df_stats_errori)
```

	Mediana	Varianza	Dev_Std
ARIMA	0.3974	0.1498	0.3871
ARIMAX	0.3207	0.1399	0.3741
ARIMAX_Eso_Prev	0.3579	0.1516	0.3894
TFM	0.3287	0.1881	0.4337
VAR_S	0.4204	0.1936	0.4400
VAR_D	0.3802	0.1549	0.3936
VECM	0.4153	0.1641	0.4051




Figure 38: Distribuzione approssimata degli errori di previsione per ciascun modello adattato.

Distribuzione e Dispersione degli Errori

L'analisi degli indici di posizione e variabilità offre ulteriori spunti sulla stabilità dei modelli e sull'impatto della previsione delle esogene:

- **Mediana degli Errori:** L'ARIMAX (Ex-Post) mantiene la mediana più contenuta (0.3207), rappresentando lo scenario ideale. Tuttavia, è fondamentale notare come l'ARIMAX con esogene previste registri una mediana di 0.3579. Sebbene superiore al caso ideale, questo valore rimane nettamente inferiore sia al benchmark ARIMA (0.3974) che al VAR Dinamico (0.3802). Ciò dimostra che, anche introducendo l'errore di previsione delle covariate, la struttura del modello cattura meglio la tendenza centrale della serie rispetto agli approcci alternativi.
- **Varianza e Stabilità:** L'ARIMA univariato si conferma estremamente stabile con una varianza di 0.1498, leggermente inferiore a quella dell'ARIMAX con esogene previste (0.1516). Questo risultato è coerente con la teoria: dover stimare occupazione e reddito aggiunge una fonte di "rumore" che aumenta leggermente la dispersione degli errori rispetto a un modello univariato puro. Tuttavia, la varianza di questo ARIMAX rimane comunque inferiore a quella del VAR Dinamico (0.1549) e nettamente migliore del VAR Statico (0.1936) e del TFM (0.1881).
- **Costo dell'Incertezza (Ex-Post vs Ex-Ante):** Il confronto tra le due versioni dell'ARIMAX quantifica il valore del conoscere il futuro. Passando dalle esogene note a quelle previste, la deviazione standard dell'errore aumenta marginalmente da 0.3741 a 0.3894. Questo incremento contenuto suggerisce che i modelli ausiliari utilizzati per prevedere Occupazione e Reddito sono sufficientemente robusti da non compromettere la validità dell'approccio ARIMAX in un contesto operativo reale.
- **VECM:** Il modello VECM, pur incorporando le relazioni di lungo periodo, mostra performance inferiori in termini di mediana (0.4153) e una varianza (0.1641) superiore sia all'ARIMA che all'ARIMAX (in entrambe le configurazioni), confermando la difficoltà nel tradurre la cointegrazione in vantaggi previsivi a breve termine per questo specifico dataset.

```
require(Metrics)

# Tabella riassuntiva media
results_media = data.frame(
  MSE = c(mse(actual_prod, pred_arima),
          mse(actual_prod, pred_arimax_expost),
          mse(actual_prod, pred_arimax_exante),
          mse(actual_prod, pred_tfm),
          mse(actual_prod, pred_var_statico),
          mse(actual_prod, pred_var_dim),
          mse(actual_prod, pred_vecm)),
  MAE = c(mae(actual_prod, pred_arima),
```

```

    mae(actual_prod, pred_arimax_expost),
    mae(actual_prod, pred_arimax_exante),
    mae(actual_prod, pred_tfm),
    mae(actual_prod, pred_var_statico),
    mae(actual_prod, pred_var_dim),
    mae(actual_prod, pred_vecm))
)

rownames(results_media) = c("ARIMA Univariato",
                           "ARIMAX",
                           "ARIMAX - Esog. prev.",
                           "TFM (Stabile)",
                           "VAR(2) - Stabile",
                           "VAR(2) - Dinamico",
                           "VECM")

print(round(results_media,4))

```

	MSE	MAE
ARIMA Univariato	0.4090	0.5120
ARIMAX	0.3376	0.4476
ARIMAX - Esog. prev.	0.3649	0.4651
TFM (Stabile)	0.4250	0.4904
VAR(2) - Stabile	0.4590	0.5189
VAR(2) - Dinamico	0.4213	0.5191
VECM	0.4123	0.5014

Analisi delle Metriche Globali (MSE e MAE)

Le metriche aggregate offrono una visione chiara della gerarchia prestazionale dei modelli, confermando la solidità dell'approccio con variabili esogene anche in condizioni operative reali:

- ARIMAX (Scenario Ideale/Ex-Post): rappresenta il benchmark assoluto del confronto, registrando l'errore medio più basso sia in termini di MSE (0.3376) che di MAE (0.4476). Questo valore rappresenta il limite teorico raggiungibile conoscendo perfettamente il futuro delle esogene.
- ARIMAX con Esogene Previste (Ex-Ante): Il modello ARIMAX alimentato con le stime di Occupazione e Reddito (ottenute tramite modelli ARIMA ausiliari) registra un MSE di 0.3649 e un MAE di 0.4651. Sebbene si osservi un fisiologico incremento dell'errore rispetto allo scenario ideale (+8% circa sul MSE), questo modello è comunque migliore rispetto a tutti gli altri approcci alternativi (ARIMA, TFM, VAR, VECM). Ciò dimostra

che il guadagno informativo derivante dalla struttura ARIMAX supera il “rumore” introdotto dalla necessità di stimare i regressori.

- ARIMA: Rappresenta un solido competitor con un MSE di 0.4090 e un MAE di 0.5120. Sebbene il suo errore medio assoluto (MAE) sia superiore al TFM e al VECM, il suo errore quadratico (MSE) è contenuto, indicando una buona capacità di evitare errori estremi (outlier), superando in stabilità i modelli multivariati complessi.
- VECM: Il modello a correzione dell'errore mostra una performance intermedia, con un MSE di 0.4123 e un MAE di 0.5014. Pur catturando le relazioni di lungo periodo, non riesce a eguagliare la precisione puntuale dell'ARIMAX (anche nella versione con esogene previste), suggerendo che il riequilibrio di lungo periodo ha un impatto limitato sulla previsione a breve termine ($h = 1$).
- TFM: Ottiene un buon risultato in termini di MAE (0.4904), posizionandosi meglio dell'ARIMA e del VECM su questa metrica. Tuttavia, il MSE più elevato (0.4250) segnala una maggiore varianza negli errori, penalizzando la valutazione complessiva rispetto ai modelli ARIMAX.
- VAR(2): Entrambe le versioni, statico (MAE 0.5189) e dinamico (MAE 0.5191), mostrano le performance peggiori del set. L'elevato numero di parametri da stimare sembra introdurre una quota di rumore statistico che degrada la precisione predittiva nell'insieme di test rispetto agli approcci a singola equazione.

In conclusione, l'analisi dimostra che l'ARIMAX è la scelta migliore: la versione con esogene previste mantiene un vantaggio competitivo netto, con un MSE (0.3649) inferiore a quello del miglior modello alternativo.

```
# Tabella per visualizzare l'errore puntuale (per i primi 12 mesi)
res_puntuale = data.frame(
  Mese = 1:n_test,
  Error_ARIMA = abs(e_arima),
  Error_ARMAX = abs(e_arimax),
  Error_TFM = abs(e_tfm),
  Error_VAR_S = abs(e_var_s),
  Error_VAR_D = abs(e_var_d),
  Error_VECM = abs(e_VECM)
)

print(round(res_puntuale[1:12,],4))
```

	Mese	Error_ARIMA	Error_ARMAX	Error_TFM	Error_VAR_S	Error_VAR_D	Error_VECM
1	1	0.3337	0.0626	0.0842	0.3474	0.3659	0.0840
2	2	0.4307	0.5814	0.2503	0.0982	0.3104	0.2790

3	3	1.2016	1.5423	1.4492	0.8708	1.0939	1.2807
4	4	1.4992	0.9259	1.0146	1.9349	1.6898	1.4405
5	5	0.1430	0.4840	0.9639	0.5674	0.2771	1.0427
6	6	0.4726	0.3912	0.1379	0.3939	0.4522	0.6544
7	7	0.4097	0.2211	0.4177	0.0690	0.2107	0.5141
8	8	0.5779	0.2553	0.7767	1.1035	0.8470	0.8283
9	9	0.2860	0.2685	1.1583	0.6736	0.4901	0.8445
10	10	0.1671	0.0494	0.1837	0.1374	0.0396	0.0124
11	11	0.2022	0.2340	0.0373	0.0483	0.1429	0.1366
12	12	0.3974	0.5780	0.1302	0.2152	0.3007	0.2886

Test di Diebold-Mariano

Ora per verificare che gli errori di previsione siano significativamente diversi tra i modelli si procede con i test di Diebold-Mariano.

```
# -----
# Matrice Completa del Test di Diebold-Mariano
# -----

mod_names <- names(Lista_errori)
n_mod <- length(mod_names)

dm_matrix <- matrix(NA, nrow = n_mod, ncol = n_mod)
rownames(dm_matrix) <- mod_names
colnames(dm_matrix) <- mod_names

# Loop per riempire la matrice con i p-value
# H0: Il modello i e il modello j hanno la stessa accuratezza (MSE)
# H1: Il modello i è più accurato del modello j (alternative = "less")
for (i in 1:n_mod) {
  for (j in 1:n_mod) {
    if (i != j) {
      test_res <- forecast::dm.test(Lista_errori[[i]],
                                   Lista_errori[[j]], h = 1,
                                   alternative = "less")
      dm_matrix[i, j] <- test_res$p.value
    }
  }
}

# Arrotondamento per una migliore visualizzazione
```

```
# Matrice dei p-value di D-M (H1: riga più accurata di colonna):
print(round(dm_matrix, 4))
```

	ARIMA	ARIMAX	ARIMAX_Eso_Prev	TFM	VAR_S	VAR_D	VECM
ARIMA	NA	0.9507	0.9382	0.3977	0.1384	0.2890	0.4711
ARIMAX	0.0493	NA	0.2215	0.0241	0.0676	0.0707	0.0631
ARIMAX_Eso_Prev	0.0618	0.7785	NA	0.1173	0.0395	0.0463	0.0521
TFM	0.6023	0.9759	0.8827	NA	0.3472	0.5214	0.5927
VAR_S	0.8616	0.9324	0.9605	0.6528	NA	0.9174	0.7988
VAR_D	0.7110	0.9293	0.9537	0.4786	0.0826	NA	0.5827
VECM	0.5289	0.9369	0.9479	0.4073	0.2012	0.4173	NA

Il modello con esogene note si conferma il migliore in assoluto. Supera in modo statisticamente significativo ARIMA ($p = 0.049$) e TFM ($p = 0.024$), dimostrando che l'informazione "perfetta" delle variabili esterne è determinante. Il risultato più rilevante è che l'ARIMAX mantiene la sua superiorità anche dovendo stimare gli input. È statisticamente più accurato del VAR (sia statico che dinamico) con un livello di confidenza del 95% ($p < 0.05$) e supera il VECM al limite della significatività ($p = 0.052$). Quindi la complessità dei sistemi multivariati (VAR, VECM) non paga l'approccio a singola equazione ARIMAX, anche nella sua versione operativa reale, è statisticamente preferibile per prevedere la produzione industriale.

Conclusioni

In conclusione, l'ARIMAX emerge come il modello più performante del confronto, superando le iniziali impressioni visive fornite dal grafico dei livelli. Sebbene a un'occhiata superficiale le traiettorie possano apparire simili o talvolta scostate, l'analisi analitica rivela che l'ARIMAX offre non solo l'errore medio più basso (MAE di 0.4476), ma anche la maggiore stabilità predittiva, testimoniata dalla minor varianza degli errori (0.1399).

Per comprendere appieno questo risultato, è fondamentale spiegare come la varianza influenza le metriche di errore:

- **Varianza e Precisione:** Una varianza contenuta indica che gli errori del modello sono concentrati vicino alla loro media, rendendo le previsioni più affidabili e costanti nel tempo.
- **Impatto sul MSE:** Poiché il Mean Squared Error (MSE) eleva gli scostamenti al quadrato, esso è estremamente sensibile ai valori anomali; l'ARIMAX, avendo la varianza più bassa, evita i grandi errori che invece penalizzano modelli più complessi come il VAR.

- **Affidabilità rispetto al MAE:** Mentre il MAE descrive l'errore tipico, la bassa varianza dell'ARIMAX assicura che tale errore non oscilli drasticamente tra i mesi, garantendo una precisione superiore anche nelle fasi di maggiore volatilità della serie.

In sintesi, la combinazione di un errore medio ridotto e di una varianza minima conferma che l'ARIMAX è il modello che meglio bilancia l'accuratezza puntuale con la stabilità complessiva del sistema.

Conclusioni Finali

Il presente studio ha analizzato le dinamiche intercorrenti tra produzione industriale, occupazione e reddito personale reale negli Stati Uniti, delineando un sistema caratterizzato da forti interdipendenze.

L'analisi delle Impulse Response Functions e della Causalità di Granger ha evidenziato il ruolo della produzione industriale come motore primario del ciclo economico. Gli shock produttivi si trasmettono con rapidità al mercato del lavoro e, successivamente, al reddito delle famiglie, confermando una struttura di trasmissione “dal lato dell’offerta” che sostiene la domanda aggregata.

Sul piano della modellistica predittiva, il confronto tra approcci univariati e multivariati ha evidenziato un chiaro compromesso tra complessità e accuratezza. Sebbene il modello VAR(2) sia stato in grado di catturare le interazioni endogene del sistema con eccellente aderenza ai dati storici, il modello ARIMAX è risultato il migliore in termini di capacità previsiva nell'insieme di verifica. La superiorità dell'ARIMAX, validata statisticamente dal test di Diebold-Mariano, dimostra che l'integrazione mirata di variabili esogene (occupazione e reddito) permette di ridurre la varianza dell'errore rispetto ai modelli puramente autoregressivi, senza incorrere nei rischi di sovradattamento tipici dei sistemi VAR.

In sintesi, i risultati suggeriscono che per il monitoraggio dei tassi di crescita della produzione industriale, un approccio che combini la struttura ARIMA con l'informazione contemporanea del mercato del lavoro offra il miglior bilanciamento tra rigore teorico e affidabilità operativa.

Appendice

Uso Intelligenza Artificiale

L'intelligenza artificiale per la realizzazione di questo eleaboarto è stata utilizzata per diverse cose:

- Consigli e validazione dell'interpretazione economica delle serie storiche prese in considerazione.
- Correzione eventuali errori grammaticali o di sintassi nei commenti e nelle interpretazioni.
- Aiuto a livello di codice in particolare:
 - Grafici con la libreria *ggplot*.
 - Ottimizzazione del codice per il calcolo delle previsioni dei modelli e metriche degli errori.
 - Costruzione dei cicli *for* per la creazione della matrice relativa ai p -value dei test di Diebold-Mariano.
- Traduzioni di alcuni testi in inglese relativi a cosa facessero riferimento i codici delle serie storiche della *FRED*.
- Formattazione dei parametri per il render del file quarto (indice, descrizione sotto ai grafici, ecc.)